

強化学習の数理_1_基礎編

強化学習の数理的基礎 — MDPとBellman方程式から体系的に学ぶ

🔗 シリーズ全体の目次

- [強化学習の数理 1 基礎編](#) (本稿) — 古典的RL理論(MDP・Bellman方程式・DP・TD・方策勾配)
- [強化学習の数理 2 深層学習編](#) — 深層強化学習(DQN・A2C・PPO・SAC等)
- [強化学習の数理 3 演習 手計算編](#) — 上記2冊の導出を手計算で再構成する演習
- [強化学習の数理 4 演習 実践コーディング編](#) — 上記2冊のアルゴリズムをコードで実装する演習

📖 本テキストについて

本テキストは、**マルコフ決定過程 (Markov Decision Process; MDP)** の定義と **Bellman方程式** の導出を出発点として、強化学習 (Reinforcement Learning; RL) の理論的基礎を体系的に解説するものである。対象読者として物理学修士レベルの数学(解析学、線形代数、確率論の基礎、変分法)の素養を仮定し、式展開・証明を省略せずに示す。同時に、「いま何のためにこの計算をしているのか」という目的意識と直観的理解を随所で強調する。

深層学習を用いた現代的手法(DQN、PPOなど)は本テキストの範囲外とするが、最終章および各所の展望において、それらへ自然に接続できるよう構成している。

目次

- **第0章** 序論 — 強化学習とは何か、そしてなぜMDPなのか
- **第1章** マルコフ決定過程 (MDP) の定義
- **第2章** 収益と価値関数 — 「良さ」の定量化
- **第3章** Bellman期待方程式 — 価値の自己無撞着方程式
- **第4章** 最適性とBellman最適方程式
- **第5章** Bellman作用素と不動点定理 — 理論の心臓部
- **第6章** 動的計画法 — モデルが既知のときの厳密解法
- **第7章** モンテカルロ法 — モデルフリー学習への第一歩
- **第8章** 時間差分 (TD) 学習 — SARSAとQ学習

- 第9章 関数近似への入り口 — 表形式の限界を超える
- 第10章 方策勾配法 — 方策を直接最適化する
- 第11章 総括と展望 — 深層強化学習へ
- 付録A Banachの不動点定理の証明
- 付録B 連続時間極限とHamilton-Jacobi-Bellman方程式
- 付録C 記法一覧

第0章 序論 — 強化学習とは何か、そしてなぜMDPなのか

0.1 問題設定: 逐次的意思決定

強化学習が扱う問題は、一言でいえば**逐次的意思決定 (sequential decision making)** である。すなわち、

- エージェント (agent) が環境 (environment) の中に置かれ、
- 各時刻で環境の**状態 (state)** を観測し、**行動 (action)** を選択し、
- その結果として**報酬 (reward)** というスカラー信号を受け取り、環境は次の状態へ遷移する。

エージェントの目標は、**長期的に得られる報酬の総和(の期待値)を最大化するような行動の選び方(方策)を見つけること**である。

教師あり学習との決定的な違いは2点ある。

1. **正解ラベルが与えられない。** 与えられるのは「その行動がどれくらい良かったか」を示す評価的な信号(報酬)のみであり、「何をすべきだったか」という指示的な信号ではない。
2. **行動が将来に影響する。** いま選んだ行動は、直近の報酬だけでなく、将来訪れる状態、ひいては将来の報酬の分布そのものを変える。したがって「目先の報酬」と「将来のための布石」のトレードオフ、すなわち**遅延報酬 (delayed reward)** の問題を扱わねばならない。

Ⅲ 物理学者向けの直観

制御理論・最適制御の言葉でいえば、強化学習は「系のダイナミクス(ハミルトニアンや運動方程式に相当するもの)が**未知**、あるいは陽に書き下せないほど複雑な状況での最適制御」である。解析力学における作用汎関数の停留化が「軌道」を決めるように、強化学習では「累積報酬」という汎関数を最大化する「方策」を求める。実際、後述するBellman方程式の連続時間極限はHamilton-Jacobi-Bellman方程式であり、これは古典力学のHamilton-Jacobi方程式の直系の親戚である(付録B参照)。

0.2 なぜMDPという定式化を使うのか

上記の問題を数学的に扱うには、「状態」「行動」「報酬」「遷移」を確率論の言葉で厳密に定義する必要がある。その標準的な枠組みが**マルコフ決定過程 (MDP)** である。

MDPの本質は**マルコフ性**、すなわち「未来は現在の状態のみに依存し、そこに至る履歴には依存しない」という仮定にある。物理でいえば、系の状態(相空間の一点)を完全に指定すれば、その後の時間発展が過去の履歴によらず決まる、という状況に対応する。マルコフ性は一見強い仮定に見えるが、実は「**状態**」の定義を十分リッチにとれば多くの問題は**マルコフ化できる**(履歴そのものを状態に含めればよい)。問題は、そのようにして得られる状態空間が巨大になりうることであり、これが後半で扱う「関数近似」の動機となる。

MDPを採用する最大の利点は、**Bellman方程式という再帰的構造**が得られることである。長期的な累積報酬という一見大域的な量が、「1ステップの報酬+残りの累積報酬」という局所的な関係式に分解される。この分解こそが動的計画法の原理であり、本テキスト全体を貫く主旋律である。

0.3 本テキストの見取り図

本テキストの論理的な流れを先に示しておく。各章で「いま地図のどこにいるのか」を意識してほしい。

1. **定義 (第1-2章):** MDPと価値関数を定義する。ここで「何を最大化したいのか」が確定する。
2. **構造 (第3-5章):** 価値関数が満たす自己無撞着方程式(Bellman方程式)を導出し、その解の存在・一意性を作用素の不動点として保証する。ここが理論の核である。
3. **計算 (第6章):** 環境のモデル (P, R) が既知なら、Bellman方程式は動的計画法で解ける(方策反復・価値反復)。
4. **学習 (第7-8章):** モデルが未知のとき、**サンプル(経験)から期待値を推定**することで同じ方程式を近似的に解く。これがモンテカルロ法とTD学習であり、「強化学習らしさ」が現れる部分である。
5. **一般化 (第9-10章):** 状態空間が巨大なとき、価値関数や方策をパラメトリックな関数で近似する。ここが深層強化学習への橋渡しとなる。

📖 読み方のガイド

理論の骨格は第3～5章にある。急ぐ読者は第5章の縮小写像の議論を飛ばしても第6章以降は読めるが、「なぜ価値反復は必ず収束するのか」「なぜ最適方策は存在するのか」という根拠はすべて第5章に集約されているため、一度は精読することを強く勧める。

第1章 マルコフ決定過程 (MDP) の定義

1.1 定義

🔗 定義 1.1(マルコフ決定過程)

マルコフ決定過程 (MDP) とは、次の5つ組である:

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R, \gamma)$$

- $\mathcal{S}$: **状態空間**。本テキストでは主に有限集合($|\mathcal{S}| < \infty$)を仮定する。
- $\mathcal{A}$: **行動空間**。同じく有限集合を仮定する。
- P : **状態遷移確率(遷移カーネル)**。状態 s で行動 a をとったとき、次状態が s' になる条件付き確率

$$P(s' | s, a) = \Pr(S_{t+1} = s' | S_t = s, A_t = a)$$

- R : **報酬関数**。状態 s で行動 a をとったときに受け取る報酬の期待値

$$R(s, a) = \mathbb{E}[R_{t+1} | S_t = s, A_t = a]$$

- $\gamma \in [0, 1)$: **割引率 (discount factor)**。将来の報酬を現在の価値に換算する係数。

時刻 $t = 0, 1, 2, \dots$ において、系は

$$S_0, A_0, R_1, S_1, A_1, R_2, S_2, \dots$$

という確率過程(軌道あるいは**トラジェクトリ**と呼ぶ)を生成する。添字の慣習に注意: 行動 A_t の結果として得られる報酬を R_{t+1} と書く (Sutton & Barto の流儀)。これは「報酬は次状態 S_{t+1} とともに環境から返ってくる」という因果関係を反映した記法である。

📌 一般化についての注意

より一般には、報酬も確率変数であり、遷移と報酬の同時分布 $p(s', r | s, a)$ でMDPを定義する。このとき

$$P(s' | s, a) = \sum_r p(s', r | s, a), \quad R(s, a) = \sum_r r \sum_{s'} p(s', r | s, a)$$

と周辺化・期待値化すれば本テキストの定義に帰着する。以降の理論展開では期待報酬 $R(s, a)$ だけが本質的な役割を果たすため、この簡略化で一般性は失われない。また、連続状態・連続行動への拡張は和を積分に、確率を確率密度に置き換えることで(測度論的な注意を払えば)形式的に同様に進む。

1.2 マルコフ性 — この定式化の心臓

定義1.1の遷移カーネルが S_t, A_t のみに依存し、それ以前の履歴 $H_t = (S_0, A_0, R_1, \dots)$ に依存しないこと、すなわち

$$\Pr(S_{t+1} = s' | S_t, A_t, S_{t-1}, A_{t-1}, \dots, S_0, A_0) = \Pr(S_{t+1} = s' | S_t, A_t)$$

を**マルコフ性**という。これは「状態 S_t が、未来を予測するのに必要な情報をすべて含んでいる」という主張であり、統計力学における「十分統計量としての熱力学状態」の考え方に近い。気体の巨視的挙動を予測するのに個々の分子の履歴は不要で、現在の (P, V, T) が分かればよい、というのと同型の発想である。

⚠ マルコフ性が破れる場合

現実の問題では、エージェントが観測できるのが状態の一部だけ(**部分観測**)であることが多い。この場合は部分観測マルコフ決定過程 (POMDP) という拡張が必要になる。深層強化学習でリカレントネットワーク(LSTM等)が使われる一つの理由は、観測履歴を内部状態に圧縮して「近似的にマルコフな状態」を構成するためである。本テキストでは完全観測を仮定する。

1.3 方策 — エージェントの振る舞いの数学的表現

エージェントの行動の選び方を**方策 (policy)** と呼ぶ。

🔗 定義 1.2(方策)

(**定常マルコフ**)方策 π とは、各状態において行動の確率分布を与える写像である:

$$\pi(a \mid s) = \Pr(A_t = a \mid S_t = s)$$

特に、各状態で確率1である行動を選ぶ方策を**決定論的方策**といい、 $a = \pi(s)$ と書く。

一般には方策は履歴依存・時刻依存でありうるが、**無限ホライズン割引MDPにおいては、定常マルコフ方策のクラスの中に最適方策が存在することが知られている**(第5章で最適方策の存在を示す際、この事実の核心部分を証明する)。そのため以降、方策といえば定常マルコフ方策を指す。

1.4 方策を固定すると:マルコフ報酬過程への還元

方策 π を一つ固定すると、行動の自由度が消え、系は単なるマルコフ連鎖(に報酬が付随したもの、**マルコフ報酬過程 (MRP)**)になる。このときの実効的な遷移行列と期待報酬ベクトルを

$$P^\pi(s' \mid s) := \sum_{a \in \mathcal{A}} \pi(a \mid s) P(s' \mid s, a), \quad R^\pi(s) := \sum_{a \in \mathcal{A}} \pi(a \mid s) R(s, a)$$

と定義する。 P^π は各行の和が1の**確率行列 (stochastic matrix)** である。

≡ 物理との対応:マスター方程式

状態の確率分布を行ベクトル $\mu_t \in \mathbb{R}^{|S|}$ ($\mu_t(s) = \Pr(S_t = s)$) で表すと、その時間発展は

$$\mu_{t+1} = \mu_t P^\pi$$

となる。これは離散時間のマスター方程式に他ならない。エルゴード的なマルコフ連鎖なら μ_t は定常分布 μ^π ($\mu^\pi = \mu^\pi P^\pi$ を満たす左固有ベクトル) に緩和する。定常分布は後に方策勾配法(第10章)で中心的な役割を果たすので、頭の片隅に置いておいてほしい。

なお、価値関数(次章)の計算では分布 μ_t を「前向きに」発展させるのではなく、報酬の期待値を「後ろ向きに」伝播させる。前者が Schrödinger 描像(分布が動く)、後者が Heisenberg 描像(観測量=価値が動く)に対応する、と見ると双対構造が見通しよく理解できる。

1.5 エピソード的タスクと継続的タスク

タスクには、明確な終端がある**エピソード的タスク**(ゲームの1プレイ、迷路の1試行など)と、終端のない**継続的タスク**がある。終端状態は「自分自身に確率1で遷移し、報酬0を出し続ける吸収状態」としてモデル化すれば、両者は統一的に扱える。本テキストは主に継続的タスク(無限ホライズン)の枠組みで理論を展開し、エピソード的タスクはその特殊ケースとみなす。

第2章 収益と価値関数 — 「良さ」の定量化

2.1 収益(リターン)の定義と割引の意味

エージェントが最大化したいのは「長期的な報酬の総和」であった。これを**収益 (return)**として定義する。

🔗 定義 2.1(割引収益)

時刻 t 以降の**割引収益**を次で定義する:

$$G_t := R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

なぜ割引率 $\gamma < 1$ を導入するのか。理由は少なくとも3つある。

1. **数学的収束性。** 報酬が有界($|R_t| \leq R_{\max}$)であれば、

$$|G_t| \leq \sum_{k=0}^{\infty} \gamma^k R_{\max} = \frac{R_{\max}}{1-\gamma} < \infty$$

となり、無限和が必ず絶対収束する。 $\gamma = 1$ では無限ホライズンで発散しうる。

2. **不確実な未来の減価。** 遠い将来の予測は不確実であり、また(生物学的・経済学的に)即時の報酬のほうが価値が高い、という妥当なモデル化。金融における割引現在価値と同じ発想である。

3. 実効的な時間スケールの設定。幾何級数の重み $\gamma^k = e^{k \ln \gamma} \approx e^{-k(1-\gamma)}$ ($\gamma \rightarrow 1$) より、エージェントが実質的に考慮する未来の長さ(実効ホライズン)は

$$\tau_{\text{eff}} \sim \frac{1}{1-\gamma}$$

程度である。 $\gamma = 0.99$ なら約100ステップ先までを「見て」意思決定する。物理でいう緩和時間・スクリーニング長のパラメータだと思えばよい。

🔗 Laplace変換的視点

割引収益は、報酬の時系列 $\{R_{t+k+1}\}_k$ の母関数(離散Laplace変換、 z 変換で $z = \gamma$ と置いたもの)と見ることができる。 γ は「どの時間スケールの構造を重視するか」を選ぶ複素周波数のような役割を果たす。

収益の定義から、直ちに次の再帰関係が従う。これが本テキスト最重要の恒等式である:

$$G_t = R_{t+1} + \gamma(R_{t+2} + \gamma R_{t+3} + \dots) = R_{t+1} + \gamma G_{t+1} \quad (2.1)$$

「いまの収益 = 直近の報酬 + 割り引いた将来の収益」。この1行がBellman方程式のすべての源泉である。

2.2 状態価値関数と行動価値関数

収益 G_t は確率変数である(軌道ごとに値が異なる)。方策の良さを評価するには、その期待値をとる必要がある。

🔗 定義 2.2(価値関数)

方策 π のもとでの状態価値関数 (state-value function) を

$$V^\pi(s) := \mathbb{E}_\pi[G_t \mid S_t = s] = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s\right]$$

と定義する。また、行動価値関数 (action-value function, Q関数) を

$$Q^\pi(s, a) := \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a]$$

と定義する。ここで $\mathbb{E}_\pi$ は「行動が方策 π に従って選ばれ、状態遷移が P に従う」ときの軌道の分布に関する期待値を表す。

言葉でいえば:

- $V^\pi(s)$: 「状態 s から出発し、以後ずっと π に従ったときに得られる収益の期待値」。状態の良さを測る。
- $Q^\pi(s, a)$: 「状態 s でまず行動 a をとり(この最初の1手だけは π に従わなくてよい)、その後は π に従ったときの期待収益」。状態・行動ペアの良さを測る。

なぜ Q 関数をわざわざ導入するのか。 $Q^\pi(s, a)$ は「 s で a を選ぶことの良さ」を直接教えてくれるため、**方策の改善(どの行動を選ぶべきかの判断)に直結する**からである。実際、第6章の方策改善、第8章の Q 学習では Q が主役になる。さらに重要なことに、 Q を使えば行動選択の際に環境モデル P が不要になる(V だけから行動を選ぶには「 a をとったら次にどの s' に行くか」の知識、すなわち P が必要)。これがモデルフリー学習で Q が中心となる理由である。

2.3 V と Q の基本的な関係

定義から直ちに従う2つの関係式を確認する。これらは第3章の導出で部品として使う。

(i) V は Q の方策平均である。

条件付き期待値の全確率則(タワー性)より、

$$V^\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s] = \sum_a \Pr(A_t = a \mid S_t = s) \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a]$$

すなわち

$$V^\pi(s) = \sum_{a \in \mathcal{A}} \pi(a \mid s) Q^\pi(s, a) \quad (2.2)$$

(ii) Q は「即時報酬 + 次状態の V 」である。

これは次章で式(2.1)を用いて導出する(式(3.2))。

また、両者の差

$$A^\pi(s, a) := Q^\pi(s, a) - V^\pi(s)$$

を**アドバンテージ関数**と呼ぶ。「状態 s において、方策の平均的な振る舞いと比べて行動 a がどれだけ得か」を表す相対量であり、式(2.2)より $\sum_a \pi(a \mid s) A^\pi(s, a) = 0$ 、つまり方策自身のもとでの平均はゼロである。アドバンテージは方策勾配法(第10章)で分散低減の鍵となり、続編で扱うA2C/PPOなどの名前の由来でもある。

第3章 Bellman期待方程式 — 価値の自己無撞着方程式

3.1 目的意識:なぜ再帰方程式を導くのか

価値関数 $V^\pi(s)$ の定義は無限級数の期待値であり、定義通りに計算するのは(無限に長い軌道を無数にサンプルする必要があるため)非現実的である。ここでの戦略は、**無限和を直接計算する代わりに、価値関数が満たすべき「局所的な整合条件」を方程式として導き、それを解くこと**である。物理でいえば、場を無限個のソースの寄与の重ね合わせとして直接書く代わりに、場が満たす微分方程式(Poisson方程式など)を立てて境界条件のもとで解く、という発想の転換に相当する。

3.2 導出

出発点は収益の再帰関係(2.1): $G_t = R_{t+1} + \gamma G_{t+1}$ 。この両辺の条件付き期待値をとる。

$$V^\pi(s) = \mathbb{E}_\pi[G_t | S_t = s] = \mathbb{E}_\pi[R_{t+1} | S_t = s] + \gamma \mathbb{E}_\pi[G_{t+1} | S_t = s]$$

第1項と第2項を、それぞれ丁寧に展開する。

第1項(即時報酬の期待値): 行動 a について周辺化する。

$$\mathbb{E}_\pi[R_{t+1} | S_t = s] = \sum_a \pi(a | s) \mathbb{E}[R_{t+1} | S_t = s, A_t = a] = \sum_a \pi(a | s) R(s, a)$$

第2項(将来収益の期待値): 行動 a と次状態 s' について周辺化する。タワー性(繰り返し期待値の法則)より、

$$\mathbb{E}_\pi[G_{t+1} | S_t = s] = \sum_a \pi(a | s) \sum_{s'} P(s' | s, a) \mathbb{E}_\pi[G_{t+1} | S_t = s, A_t = a, S_{t+1} = s']$$

ここで**マルコフ性と方策の定常性**が決定的に効く。 $S_{t+1} = s'$ が与えられれば、それ以降の軌道の分布は (S_t, A_t) に依存しない。したがって

$$\mathbb{E}_\pi[G_{t+1} | S_t = s, A_t = a, S_{t+1} = s'] = \mathbb{E}_\pi[G_{t+1} | S_{t+1} = s'] = V^\pi(s')$$

最後の等号は、方策が時刻に依存しない(定常)ため、 V^π も時刻に依存しないことを使った。まとめると:

定理 3.1(Bellman期待方程式 — V^π)

$$V^\pi(s) = \sum_a \pi(a | s) \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V^\pi(s') \right] \quad \forall s \in \mathcal{S} \quad (3.1)$$

同じ計算を Q^π について行う。 $S_t = s, A_t = a$ で条件付けると即時報酬の期待値は $R(s, a)$ 、将来項は次状態 s' で周辺化した後、 s' での価値 $V^\pi(s')$ になるから、

$$Q^\pi(s, a) = R(s, a) + \gamma \sum_{s'} P(s' | s, a) V^\pi(s') \quad (3.2)$$

これが2.3節で予告した関係(ii)である。式(2.2) $V^\pi(s) = \sum_a \pi(a|s) Q^\pi(s, a)$ を(3.2)の右辺に代入すれば、 Q だけで閉じた方程式も得られる:

$$Q^\pi(s, a) = R(s, a) + \gamma \sum_{s'} P(s' | s, a) \sum_{a'} \pi(a' | s') Q^\pi(s', a') \quad (3.3)$$

構造の覚え方:バックアップ図

(3.1)–(3.3) はすべて同じ構造をもつ: 「**1ステップ先の全可能性(行動は π で、遷移は P で重みづけ)**を平均し、**即時報酬**を足し、 γ で割り引いて戻す」。この操作を、木構造の葉(1ステップ先)の値を根(現在)へ集約する操作と見て**バックアップ (backup)** と呼ぶ。強化学習のあらゆるアルゴリズムは、このバックアップを「厳密に行うか、サンプル

で近似するか」「全幅で行うか、1本の軌道に沿って行うか」「1ステップか、多ステップか」の違いにすぎない、という統一的視点が持てると見通しが非常に良くなる。

3.3 線形方程式としてのBellman期待方程式

式(3.1)をよく見ると、これは未知数 $\{V^\pi(s)\}_{s \in \mathcal{S}}$ に関する**連立一次方程式**である。1.4節の記法 (P^π, R^π) を使い、 V^π を $|\mathcal{S}|$ 次元の列ベクトル $\mathbf{v}^\pi$ 、 R^π をベクトル $\mathbf{r}^\pi$ とみなすと、(3.1)は

$$\mathbf{v}^\pi = \mathbf{r}^\pi + \gamma P^\pi \mathbf{v}^\pi \quad (3.4)$$

とコンパクトに書ける。移項して

$$(I - \gamma P^\pi) \mathbf{v}^\pi = \mathbf{r}^\pi$$

$(I - \gamma P^\pi)$ は**可逆か**? P^π は確率行列なので、そのスペクトル半径は $\rho(P^\pi) = 1$ (Perron-Frobenius: 最大固有値1、対応する右固有ベクトルは全成分1のベクトル)。よって γP^π の固有値はすべて絶対値 $\leq \gamma < 1$ であり、 $I - \gamma P^\pi$ の固有値は0にならない。したがって可逆で、

定理 3.2(Bellman期待方程式の解の存在と一意性)

$\gamma < 1$ のとき、Bellman期待方程式(3.4)は一意解

$$\mathbf{v}^\pi = (I - \gamma P^\pi)^{-1} \mathbf{r}^\pi \quad (3.5)$$

をもつ。

さらに、 $\|\gamma P^\pi\| < 1$ (スペクトル半径の意味で) なので、逆行列は**Neumann級数**で展開できる:

$$\mathbf{v}^\pi = \sum_{k=0}^{\infty} (\gamma P^\pi)^k \mathbf{r}^\pi = \mathbf{r}^\pi + \gamma P^\pi \mathbf{r}^\pi + \gamma^2 (P^\pi)^2 \mathbf{r}^\pi + \dots \quad (3.6)$$

この級数の各項は明快な意味をもつ: $(P^\pi)^k$ の (s, s') 成分は「 s から k ステップで s' に到達する確率」だから、第 k 項は「 k ステップ後に受け取る期待報酬を γ^k で割り引いたもの」。つまり(3.6)は価値関数の定義(定義2.2)そのものを行列語で書き直したものであり、Bellman方程式を解くことと無限級数を足し上げることが等価であると確認できた。

三 物理との対応: グリーン関数・伝播関数

$(I - \gamma P^\pi)^{-1}$ は、格子上の拡散問題や摂動論に現れるレゾルベント(グリーン関数) $G = (E - H)^{-1}$ の完全な類似物である。Neumann級数(3.6)は「報酬というソースが、遷移という伝播を通じて各状態に染み出し、その重ね合わせが価値になる」というダイソン級数的描像を与える。 γ が1に近いほど「長距離の伝播」が効き、 $(1 - \gamma)^{-1}$ とい

う因子で価値のスケールが増大する。数値計算の観点では、 $\gamma \rightarrow 1$ で $(I - \gamma P^\pi)$ の条件数が悪化する、と読める。

計算量の観点。 (3.5)の直接解法は $O(|S|^3)$ にかかる。状態数が数百万を超えると非現実的であり、代わりに(3.6)の部分和を逐次計算する**反復法**が使われる。これが次章以降の「反復的方策評価」であり、その収束を保証するのが第5章の縮小写像の理論である。ここに「厳密解法 → 反復法 → サンプル近似(学習)」という本テキストの発展の芽がすでに見えている。

第4章 最適性とBellman最適方程式

4.1 方策の順序と最適価値関数

ここまでの議論は「与えられた方策 π の評価」だった。いよいよ本題である「最良の方策を見つける」問題に移る。まず「良い方策」を定義する。

🔗 定義 4.1(方策の半順序と最適方策)

方策 π' が π 以上である($\pi' \succeq \pi$)とは、

$$V^{\pi'}(s) \geq V^\pi(s) \quad \forall s \in \mathcal{S}$$

が成り立つことをいう。すべての方策以上であるような方策 π^* を**最適方策**と呼ぶ。

これは**半順序**であることに注意。一般の2方策は比較不能でありうる(状態Aでは π が勝ち、状態Bでは π' が勝ち、など)。したがって「すべての状態で同時に他のどの方策にも負けないう方策」が存在するかは自明ではない。**存在する**というのが有限MDPの著しい性質であり、第5章で証明する。

一方、最適「価値関数」の方は無条件に定義できる:

$$V^*(s) := \max_{\pi} V^\pi(s), \quad Q^*(s, a) := \max_{\pi} Q^\pi(s, a)$$

(状態ごとに別々の方策で最大化してよい。有限MDPでは定常方策の集合上の最大値が達成されることが後で分かる。)

4.2 Bellman最適方程式の導出

V^* が満たす方程式を導く。鍵となる直観は次の通りである:

最適に振る舞うとは、「最初の1手を最適に選び、その後も最適に振る舞う」ことである。

これは動的計画法における**Bellmanの最適性原理**:「最適方策の部分列(途中から先)もまた、その途中の状態を初期条件とする部分問題の最適方策である」の言い換えである。解析力学

で、停留作用の軌道の任意の部分区間がやはり停留軌道である、という事実と同じ構造をもつ。

まず Q^* と V^* の関係から。最適方策 π^* が存在すると仮定すると(存在は第5章で示す)、 $V^* = V^{\pi^*}$, $Q^* = Q^{\pi^*}$ であり、式(2.2)より

$$V^*(s) = \sum_a \pi^*(a | s) Q^*(s, a) \leq \max_a Q^*(s, a)$$

逆に、もし $V^*(s) < \max_a Q^*(s, a)$ なら、状態 s で $\arg \max_a Q^*(s, a)$ を選び、その後 π^* に従う方策は π^* を厳密に上回る収益を s から得るため、 V^* の最大性に反する。よって

$$V^*(s) = \max_{a \in \mathcal{A}} Q^*(s, a) \quad (4.1)$$

方策平均 $\sum_a \pi(a|s)(\cdot)$ が $\max_a(\cdot)$ に置き換わったことに注目してほしい。これが「期待方程式」と「最適方程式」の唯一かつ本質的な違いである。一方、 Q^* と次状態の V^* の関係は、(3.2)の導出と全く同様で(最初の1手 a を固定してしまえば、残りは「次状態から最適に振る舞う」だけなので)

$$Q^*(s, a) = R(s, a) + \gamma \sum_{s'} P(s' | s, a) V^*(s') \quad (4.2)$$

(4.1)と(4.2)を互いに代入し合うと、それぞれ閉じた方程式が得られる:

定理 4.2(Bellman最適方程式)

$$V^*(s) = \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) V^*(s') \right] \quad (4.3)$$

$$Q^*(s, a) = R(s, a) + \gamma \sum_{s'} P(s' | s, a) \max_{a'} Q^*(s', a') \quad (4.4)$$

4.3 最適方程式の含意:貪欲方策で十分

式(4.1)–(4.2)は極めて重要な実用的帰結をもつ。もし Q^* が手に入れば、最適方策は

$$\pi^*(s) = \arg \max_a Q^*(s, a)$$

という**貪欲 (greedy) 方策**、すなわち各状態で Q^* を最大化する行動を選ぶだけで得られる。「無限の未来を見据えた大域的最適化」が、「 Q^* という1つの関数に対する各状態での局所的な最大化」に還元されるのである。 Q^* には将来のすべての情報が既に織り込み済みだからだ。プランニング(先読み探索)なしに表引きだけで最適に行動できる——これが Q 関数を学習することの威力であり、 Q 学習(第8章)、ひいてはDQN(続編)の思想的基盤である。

期待方程式との決定的な違い:非線形性

Bellman期待方程式(3.1)は線形で、解は逆行列(3.5)で閉じた形に書けた。しかし Bellman最適方程式(4.3)は $\max$ 演算子のために**区分線形かつ凸だが非線形**であり、一

般に閉じた形の解はない。したがって反復法で解くしかない。その反復法が必ず一意解に収束することを保証するのが、次章の縮小写像の理論である。ここが本テキストの理論的クライマックスである。

第5章 Bellman作用素と不動点定理 — 理論の心臓部

5.1 目的意識

前章までで2つの方程式が得られた:

- **Bellman期待方程式(3.1):** 解けば V^π が求まる(方策評価)。
- **Bellman最適方程式(4.3):** 解けば V^* が求まる(最適制御)。

本章の目標は、これらの方程式を関数空間上の写像(作用素)の不動点問題として捉え直し、次の3点を一挙に証明することである。

1. 解が存在して一意であること。
2. 任意の初期値から反復適用するだけで解に収束すること(アルゴリズムの収束保証)。
3. 最適な**方策**(価値関数だけでなく)が存在すること。

物理学徒には、自己無撞着方程式(Hartree-Fock方程式や平均場方程式)を逐次代入で解くとき「いつ収束が保証されるか」という馴染みの問いの、厳密に答えが出る例だと思ってもらえばよい。

5.2 Bellman作用素の定義

価値関数の空間 $\mathbb{R}^{|S|}$ 上に、2つの作用素を定義する。任意の $v \in \mathbb{R}^{|S|}$ (v は真の価値関数とは限らない任意の「価値関数候補」)に対し、

定義 5.1(Bellman作用素)

Bellman期待作用素 $T^\pi : \mathbb{R}^{|S|} \rightarrow \mathbb{R}^{|S|}$:

$$(T^\pi v)(s) := \sum_a \pi(a | s) \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) v(s') \right]$$

Bellman最適作用素 $T^* : \mathbb{R}^{|S|} \rightarrow \mathbb{R}^{|S|}$:

$$(T^* v)(s) := \max_a \left[R(s, a) + \gamma \sum_{s'} P(s' | s, a) v(s') \right]$$

定義から明らかに、

- Bellman期待方程式(3.1)は「 V^π は T^π の不動点」: $T^\pi V^\pi = V^\pi$
- Bellman最適方程式(4.3)は「 V^* は T^* の不動点」: $T^* V^* = V^*$

と言い換えられる。ベクトル記法では $T^\pi v = \mathbf{r}^\pi + \gamma P^\pi v$ (アフィン写像) である。

5.3 縮小性の証明

関数空間に **sup ノルム (最大ノルム)**

$$\|v\|_\infty := \max_{s \in \mathcal{S}} |v(s)|$$

を入れる。 $(\mathbb{R}^{|\mathcal{S}|}, \|\cdot\|_\infty)$ は完備な距離空間 (Banach空間) である。

定理 5.2 (γ -縮小性)

T^π と T^* はともに sup ノルムに関して係数 γ の縮小写像である。すなわち任意の $u, v \in \mathbb{R}^{|\mathcal{S}|}$ に対して

$$\|T^\pi u - T^\pi v\|_\infty \leq \gamma \|u - v\|_\infty, \quad \|T^* u - T^* v\|_\infty \leq \gamma \|u - v\|_\infty$$

証明 (T^π の場合): 各成分について、

$$\begin{aligned} |(T^\pi u)(s) - (T^\pi v)(s)| &= \left| \gamma \sum_a \pi(a|s) \sum_{s'} P(s'|s, a) [u(s') - v(s')] \right| \\ &\leq \gamma \sum_a \pi(a|s) \sum_{s'} P(s'|s, a) |u(s') - v(s')| \\ &\leq \gamma \sum_a \pi(a|s) \sum_{s'} P(s'|s, a) \|u - v\|_\infty = \gamma \|u - v\|_\infty \end{aligned}$$

1行目で報酬項が差し引きで消えること、3行目で π と P が確率分布 (和が1) であることを使った。全状態 s について成り立つので、左辺の最大値をとって主張を得る。■

証明 (T^* の場合): $\max$ が入るため一工夫要る。次の補題を使う。

補題 5.3

任意の関数 $f, g: \mathcal{A} \rightarrow \mathbb{R}$ に対し、

$$\left| \max_a f(a) - \max_a g(a) \right| \leq \max_a |f(a) - g(a)|$$

補題の証明: $a^\dagger := \arg \max_a f(a)$ とすると、

$$\max_a f(a) - \max_a g(a) = f(a^\dagger) - \max_a g(a) \leq f(a^\dagger) - g(a^\dagger) \leq \max_a |f(a) - g(a)|$$

$f \leftrightarrow g$ を入れ替えて同じ評価をすれば絶対値の主張を得る。■

この補題で $f(a) = R(s, a) + \gamma \sum_{s'} P(s'|s, a) u(s')$ 、 $g(a)$ を v 版として適用すると、

$$|(T^*u)(s) - (T^*v)(s)| \leq \max_a \left| \gamma \sum_{s'} P(s'|s, a) [u(s') - v(s')] \right| \leq \gamma \|u - v\|_\infty$$

となり、 T^π と同様に結論を得る。■

🔗 直観:なぜ縮小するのか

Bellman作用素は「1ステップ先の値の(確率的な)平均をとり、 γ 倍して戻す」操作である。平均操作は差を広げず(P の行和が1なので非拡大)、 $\gamma < 1$ 倍が差を確実に縮める。誤差が1ステップ伝播するごとに γ 倍に減衰する——価値の推定誤差は「未来からの寄与」に由来し、未来は割引されているから、と読める。逆に言えば $\gamma \rightarrow 1$ で収束は遅くなり($\gamma = 1$ では保証が消える)、割引が理論を支えていることが分かる。

5.4 Banachの不動点定理と主定理

🔗 定理 5.4(Banachの不動点定理)

(X, d) を完備距離空間、 $T: X \rightarrow X$ を縮小写像(ある $\gamma \in [0, 1)$ が存在して $d(Tx, Ty) \leq \gamma d(x, y)$) とする。このとき:

1. T の不動点 $x^* = Tx^*$ が一意に存在する。
2. 任意の初期点 x_0 から $x_{k+1} = Tx_k$ と反復すると $x_k \rightarrow x^* (k \rightarrow \infty)$ 。
3. 収束は幾何的: $d(x_k, x^*) \leq \gamma^k d(x_0, x^*)$ 。

証明は付録Aに与える(反復列がCauchy列になることを幾何級数で示す標準的な議論である)。この定理を定理5.2と組み合わせれば、直ちに次を得る:

🔗 定理 5.5(本章の主定理)

有限MDP($\gamma < 1$)において:

1. T^π の不動点は一意であり、それは V^π である。任意の v_0 から $v_{k+1} = T^\pi v_k$ は V^π に幾何的に収束する(反復的方策評価の収束保証)。
2. T^* の不動点は一意であり、それを V^* と同定できる。任意の v_0 から $v_{k+1} = T^* v_k$ は V^* に幾何的に収束する(価値反復の収束保証)。

誤差は $\|v_k - V^*\|_\infty \leq \gamma^k \|v_0 - V^*\|_\infty$ で減衰する。

T^* の不動点が本当に定義通りの V^* (全方策にわたる上限)と一致すること、およびそこから最適方策が構成できることは、次節で示す。

5.5 最適方策の存在定理

🔗 定理 5.6(最適方策の存在)

$v^\dagger$ を T^* の一意な不動点とする。 $v^\dagger$ に対する貪欲な決定論の方策

$$\pi^\dagger(s) \in \arg \max_a \left[R(s, a) + \gamma \sum_{s'} P(s'|s, a) v^\dagger(s') \right]$$

をとると、 $V^{\pi^\dagger} = v^\dagger = V^*$ が成り立つ。すなわち $\pi^\dagger$ は最適方策であり、**決定論的定常方策の中に最適方策が存在する**。

証明: 貪欲方策の定義より、 $\pi^\dagger$ は各状態で T^* の $\max$ を達成する行動を選ぶので、

$$T^{\pi^\dagger} v^\dagger = T^* v^\dagger = v^\dagger$$

つまり $v^\dagger$ は $T^{\pi^\dagger}$ の不動点でもある。定理5.5(1)より $T^{\pi^\dagger}$ の不動点は一意で $V^{\pi^\dagger}$ に等しいから、 $V^{\pi^\dagger} = v^\dagger$ 。

次に $v^\dagger = V^*$ 、すなわち任意の方策 π に対し $V^\pi \leq v^\dagger$ (成分ごと)を示す。定義より各成分で $T^\pi v \leq T^* v$ (平均は最大値を超えない)である。また T^π は**単調**: $u \leq v$ (成分ごと)ならば $T^\pi u \leq T^\pi v$ (定義中の v の係数 $\gamma \pi(a|s) P(s'|s, a) \geq 0$ がすべて非負だから)。この2つを組み合わせ、

$$V^\pi = T^\pi V^\pi \leq T^* V^\pi$$

両辺に T^* を繰り返し適用する。 T^* も同じ理由で単調なので、

$$V^\pi \leq T^* V^\pi \leq (T^*)^2 V^\pi \leq \dots \leq (T^*)^k V^\pi \xrightarrow{k \rightarrow \infty} v^\dagger$$

最後の収束は定理5.5(2)による。よって $V^\pi \leq v^\dagger = V^{\pi^\dagger}$ 。 π は任意だったから $\pi^\dagger$ は最適方策であり、 $v^\dagger = V^*$ 。■

🔗 ここまでのまとめ:理論の土台が完成した

- 最適価値関数 V^* は存在し、一意で、Bellman最適方程式の解として特徴づけられる。
- 最適方策は(決定論的定常方策として)必ず存在し、 V^* (あるいは Q^*) への貪欲化で得られる。
- どちらの価値関数も、Bellman作用素の**反復適用だけで**計算できる。収束は幾何的で、レートは γ 。

以降のすべての章は、この反復を「どう実装するか」の各論である:モデルが既知なら厳密に(第6章)、未知ならサンプルで近似して(第7-8章)、状態空間が大きいなら関数近似と組み合わせて(第9章)。

第6章 動的計画法 — モデルが既知のときの厳密解法

本章では環境モデル (P, R) が完全に既知であると仮定する。この設定での解法(動的計画法; **Dynamic Programming, DP**)は厳密には「学習」ではなく「プランニング(計画)」だが、後のすべての学習アルゴリズムの原型がここにある。

6.1 反復的方策評価

目標: 与えられた π の価値 V^π を求める(予測問題)。

定理5.5(1)より、やることは単純である: 任意の v_0 (例: 全成分0) から出発し、

$$v_{k+1}(s) \leftarrow \sum_a \pi(a|s) \left[R(s, a) + \gamma \sum_{s'} P(s'|s, a) v_k(s') \right] \quad \forall s$$

を収束まで繰り返す。誤差は γ^k で減衰するので、許容誤差 ε を達成するのに必要な反復回数は $O\left(\frac{\ln(1/\varepsilon)}{1-\gamma}\right)$ ($\ln(1/\gamma) \approx 1-\gamma$ を使った)。1反復のコストは $O(|S|^2|A|)$ 。

🔄 実装上の2つの流儀: 同期更新と非同期(in-place)更新

上式は「全状態の新しい値を古い値 v_k から一斉に計算する」**同期更新**(Jacobi法に対応)である。一方、値の配列を1つだけ持ち、更新済みの新しい値をその場で使い回す **in-place 更新**(Gauss-Seidel法に対応)も収束し、しばしばより速い。「一部の状態だけを任意の順序で更新し続けても、すべての状態が無限回更新される限り収束する」という**非同期DP**の理論もあり、これが後にサンプルベースの学習(訪れた状態だけを更新する)が正当化される伏線となる。

6.2 方策改善と方策改善定理

目標: V^π が分かったとして、 π より良い方策を作る(制御問題への一步)。

自然なアイデアは、 $Q^\pi(s, a) = R(s, a) + \gamma \sum_{s'} P(s'|s, a) V^\pi(s')$ を計算し、各状態でそれに貪欲な新方策

$$\pi'(s) := \arg \max_a Q^\pi(s, a)$$

をとることである。「1手だけ最善を尽くし、あとは元の π に従う」と仮定した評価で行動を選び直すわけだ。これが本当に改善になっていることを保証するのが次の定理である。

🔗 定理 6.1(方策改善定理)

2つの決定論的方策 π, π' が、すべての s で

$$Q^\pi(s, \pi'(s)) \geq V^\pi(s)$$

を満たすなら、 $V^{\pi'}(s) \geq V^{\pi}(s)(\forall s)$ 。さらに、ある状態で仮定の不等号が厳密なら、その状態で結論の不等号も厳密である。

証明: 仮定の不等式を出発点に、「 π' に従うステップ数」を1つずつ増やしていく展開を行う。

$$\begin{aligned}
 V^{\pi}(s) &\leq Q^{\pi}(s, \pi'(s)) \\
 &= \mathbb{E}[R_{t+1} + \gamma V^{\pi}(S_{t+1}) \mid S_t = s, A_t = \pi'(s)] && \text{(式(3.2))} \\
 &\leq \mathbb{E}_{\pi'}[R_{t+1} + \gamma Q^{\pi}(S_{t+1}, \pi'(S_{t+1})) \mid S_t = s] && \text{(仮定を } S_{t+1} \text{ に適用)} \\
 &= \mathbb{E}_{\pi'}[R_{t+1} + \gamma R_{t+2} + \gamma^2 V^{\pi}(S_{t+2}) \mid S_t = s] \\
 &\leq \dots \\
 &\leq \mathbb{E}_{\pi'}[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots \mid S_t = s] = V^{\pi'}(s)
 \end{aligned}$$

各段で仮定 $V^{\pi}(\cdot) \leq Q^{\pi}(\cdot, \pi'(\cdot))$ を次の時刻の状態に適用しており、 k 段目の残差項は $\gamma^k V^{\pi}(S_{t+k})$ で押さえられ、 V^{π} は有界だから $k \rightarrow \infty$ で消える。■

貪欲方策 π' は定義から $Q^{\pi}(s, \pi'(s)) = \max_a Q^{\pi}(s, a) \geq \sum_a \pi(a|s) Q^{\pi}(s, a) = V^{\pi}(s)$ を満たすので、定理の仮定を満たす。すなわち**貪欲化は決して方策を悪化させない**。

さらに、改善が止まったとき、つまり $V^{\pi'} = V^{\pi}$ となったときは、すべての s で

$$V^{\pi}(s) = \max_a Q^{\pi}(s, a) = \max_a \left[R(s, a) + \gamma \sum_{s'} P(s'|s, a) V^{\pi}(s') \right]$$

が成り立つ。これはBellman**最適**方程式(4.3)そのものだから、 $V^{\pi} = V^*$ 。**改善が止まる $\Leftrightarrow$ 最適に到達**、である。

6.3 方策反復 (Policy Iteration)

以上を組み合わせると、最適方策を求める最初の完全なアルゴリズムが得られる。

🔗 アルゴリズム 6.2(方策反復)

1. 任意の方策 π_0 で初期化。
2. **方策評価:** V^{π_k} を計算(線形方程式(3.5)を解くか、反復的方策評価)。
3. **方策改善:** $\pi_{k+1}(s) \leftarrow \arg \max_a [R(s, a) + \gamma \sum_{s'} P(s'|s, a) V^{\pi_k}(s')]$
4. $\pi_{k+1} = \pi_k$ なら終了(最適)。さもなければ2へ。

有限回で終了することに注意:各反復で方策は真に改善するか停止し(定理6.1)、決定論的定常方策は高々 $|A|^{|\mathcal{S}|}$ 個しかないので、同じ方策に戻ることはなく、有限回で最適方策に到達する。

6.4 価値反復 (Value Iteration)

方策反復は、内側のループ(方策評価)を毎回收束まで回すのが重い。そこで**評価を1回のバックアップで打ち切って即座に改善する**という極端な省略を考えると、更新は

$$v_{k+1}(s) \leftarrow \max_a \left[R(s, a) + \gamma \sum_{s'} P(s'|s, a) v_k(s') \right]$$

となる。これは $v_{k+1} = T^* v_k$ 、すなわち**Bellman最適作用素の反復適用そのもの**であり、定理5.5(2)がそのまま収束($v_k \rightarrow V^*$ 、レート γ^k)を保証する。これを**価値反復**と呼ぶ。反復途中の v_k はどの方策の価値関数でもない「価値関数もどき」だが、それでも不動点にさえ収束すればよい、という割り切りである。収束後(あるいは十分収束した時点で)、 v_k に貪欲な方策を出力する。

打ち切り誤差の評価も縮小性から直ちに得られる。 v に貪欲な方策を π_v とすると、

$$\|V^{\pi_v} - V^*\|_\infty \leq \frac{2\gamma}{1-\gamma} \|v - V^*\|_\infty$$

が示せる(縮小性と三角不等式による標準的な評価)。つまり価値の誤差が小さければ、そこから作った貪欲方策の性能損失も制御できる。

6.5 一般化方策反復 (GPI) — 強化学習の統一描像

方策反復(評価を完全に回す)と価値反復(評価を1回で打ち切る)は、実は連続的なスペクトルの両端である。より一般に、

- **評価プロセス**: 現在の方策に向けて価値関数を(不完全でもよいから)近づける。
- **改善プロセス**: 現在の価値関数に対して方策を(部分的にでも)貪欲化する。

という2つのプロセスを任意の粒度・順序で回す枠組みを**一般化方策反復 (Generalized Policy Iteration; GPI)**と呼ぶ。2つのプロセスは互いに「目標を動かし合う」拮抗関係にあるが、両方が同時に安定するのは $V = V^*$ かつ $\pi = \pi^*$ のときだけであり、そこが唯一の不動点になる。

🔗 GPIという見方の重要性

本テキストの以降に登場するほぼすべてのアルゴリズム——モンテカルロ制御、SARSA、Q学習、そして続編のDQNやアクター・クリティック——は、GPIの枠組みの中で「評価をどう近似するか(サンプル?ブートストラップ?関数近似?)」「改善をどう行うか(貪欲? ϵ -貪欲?勾配?)」を選んだ変種として理解できる。新しいアルゴリズムに出会ったら「これはGPIのどの部品をどう実装したものか」と問う習慣をつけると、見通しが劇的に良くなる。

6.6 具体例:2状態MDPの手計算

理論を手で確かめるため、極小の例を計算してみよう。状態 $\mathcal{S} = \{s_1, s_2\}$ 、行動 $\mathcal{A} = \{\text{stay}, \text{move}\}$ 、 $\gamma = 0.9$ とし、ダイナミクスは決定論的:

状態	行動	次状態	報酬
s_1	stay	s_1	+1
s_1	move	s_2	0
s_2	stay	s_2	+2
s_2	move	s_1	0

直観: s_2 で stay し続けるのが最高(+2 が毎ステップ)。 s_1 にいるなら、目先の +1 を捨てて move し、以後 s_2 で稼ぐべきか?——これはまさに遅延報酬のトレードオフである。

候補方策の評価。 まず「常に stay」という方策 π_0 を評価する。決定論的なのでBellman期待方程式は

$$V^{\pi_0}(s_1) = 1 + 0.9 V^{\pi_0}(s_1) \implies V^{\pi_0}(s_1) = \frac{1}{1 - 0.9} = 10$$

$$V^{\pi_0}(s_2) = 2 + 0.9 V^{\pi_0}(s_2) \implies V^{\pi_0}(s_2) = 20$$

方策改善。 Q^{π_0} を計算する:

$$Q^{\pi_0}(s_1, \text{stay}) = 1 + 0.9 \times 10 = 10, \quad Q^{\pi_0}(s_1, \text{move}) = 0 + 0.9 \times 20 = 18$$

$$Q^{\pi_0}(s_2, \text{stay}) = 2 + 0.9 \times 20 = 20, \quad Q^{\pi_0}(s_2, \text{move}) = 0 + 0.9 \times 10 = 9$$

貪欲化により $\pi_1(s_1) = \text{move}$, $\pi_1(s_2) = \text{stay}$ 。 s_1 での判断が入れ替わった:即時報酬 +1 を犠牲にしても、価値20の状態へ移るほうが($0.9 \times 20 = 18 > 10$)得だからである。

π_1 の評価と停止確認。

$$V^{\pi_1}(s_2) = 2 + 0.9 V^{\pi_1}(s_2) = 20, \quad V^{\pi_1}(s_1) = 0 + 0.9 \times 20 = 18$$

再び Q^{π_1} を計算すると $Q^{\pi_1}(s_1, \text{stay}) = 1 + 0.9 \times 18 = 17.2 < 18$ 、

$Q^{\pi_1}(s_2, \text{move}) = 0.9 \times 18 = 16.2 < 20$ で、貪欲方策は変化しない。よって $\pi_1 = \pi^*$ 、 $V^* = (18, 20)$ である。Bellman最適方程式(4.3)に代入して成立を直接確認してみたい。

第7章 モンテカルロ法 — モデルフリー学習への第一歩

7.1 パラダイムの転換:モデルからサンプルへ

第6章の方法はすべて、バックアップの計算に $P(s'|s, a)$ と $R(s, a)$ の明示的な知識を要した。しかし現実の多くの問題では、環境のモデルは未知である。手に入るのは環境と相互作用して得られる経験のサンプル、すなわち軌道 $s_0, a_0, r_1, s_1, a_1, r_2, \dots$ だけだ。ここからが本当の意味での「学習」である。

鍵となる着想は拍子抜けするほど単純である:

価値関数は期待値として定義されている。期待値はサンプル平均で推定できる。

物理学におけるモンテカルロ法(分配関数の期待値をサンプリングで評価する)と全く同じ発想であり、名前の由来も同じである。

7.2 モンテカルロ方策評価

エピソード的タスク(必ず有限時間で終端に達する)を仮定する。方策 π でエピソードを多数生成し、各エピソードで状態 s を訪れた時刻 t について、その後の実際の収益

$$G_t = r_{t+1} + \gamma r_{t+2} + \cdots + \gamma^{T-t-1} r_T$$

を計算し(エピソード終端 T まで足す)、それらの平均を $V^\pi(s)$ の推定値とする:

$$\hat{V}(s) = \frac{1}{N(s)} \sum_{i=1}^{N(s)} G^{(i)}(s)$$

定義2.2より $\mathbb{E}_\pi[G_t | S_t = s] = V^\pi(s)$ なので、この推定量は**不偏**であり、大数の法則により $N(s) \rightarrow \infty$ で真値に収束する。各エピソード内で s の初回訪問のみを数える **first-visit MC** と、全訪問を数える **every-visit MC** があり、first-visit は各サンプルが独立同分布になるため解析が容易(上記の不偏性が厳密に成り立つ)、every-visit も一致推定量である。

逐次更新形式。平均は逐次的に書き直せる。 N 個目のサンプル G を得たとき、

$$\hat{V}(s) \leftarrow \hat{V}(s) + \frac{1}{N(s)} [G - \hat{V}(s)]$$

より一般に、ステップサイズ $\alpha \in (0, 1]$ を使って

$$\hat{V}(s) \leftarrow \hat{V}(s) + \alpha [G - \hat{V}(s)] \quad (7.1)$$

とする。「**(目標値 - 現在の推定値)の一定割合だけ推定値を動かす**」というこの形は、以降すべての学習則に共通する原型である。目標値が何であるか(MCでは実収益 G)だけがアルゴリズムごとに異なる。 α を定数にすると指数移動平均になり、非定常な環境(方策が変わり続ける制御問題ではまさにそう)に追従できる。

7.3 探索の問題と ε -貪欲方策

制御(最適方策の学習)に進むには、GPIに従い「MCで Q^π を推定 $\rightarrow$ 貪欲化」を繰り返せばよさそう。 V でなく Q を推定するのは、2.2節で述べた通り、モデルなしで貪欲化するには Q が必要だからである。

しかしここで新しい、そして強化学習に固有の問題が現れる:**探索 (exploration)** である。決定論的な貪欲方策に従うと、各状態で1つの行動しか試さないため、他の行動の Q 値のサンプルが永遠に得られず、推定が改善しない。より良い行動が存在しても発見できないのだ。既知の良い行動で稼ぐこと(**活用; exploitation**)と、未知の行動を試すこと(**探索**)のジレンマである。

最も基本的な解決策が ε -貪欲方策である:

$$\pi(a | s) = \begin{cases} 1 - \varepsilon + \frac{\varepsilon}{|\mathcal{A}|} & a = \arg \max_{a'} Q(s, a') \\ \frac{\varepsilon}{|\mathcal{A}|} & \text{それ以外} \end{cases}$$

確率 $1 - \varepsilon$ で貪欲に、確率 ε で一様ランダムに行動する。すべての行動が正の確率をもつので、無限回の試行ですべての (s, a) が無限回サンプルされる。方策改善定理は ε -貪欲方策のクラス内での改善についても成立することが示せるため、「MC評価 + ε -貪欲改善」のGPIは(ε -貪欲クラス内での)最適方策に向かう。真の最適方策に収束させるには、 ε を徐々に0に近づけつつ全ペアの訪問回数が発散するようにスケジュールする(**GLIE**: Greedy in the Limit with Infinite Exploration)。

三 物理との対応:焼きなまし

ε (あるいは後述のBoltzmann方策の温度)を徐々に下げる操作は、シミュレーテッド・アニーリングにおける温度スケジュールと同じ思想である。高温(高 ε)で相空間を広く探索し、低温で良い解の周りに凝縮する。なお、 Q 値をエネルギー(の符号反転)とみなした Boltzmann 分布 $\pi(a|s) \propto e^{Q(s,a)/T}$ による探索(**softmax方策**)もよく使われ、これは続編で触れる最大エントロピー強化学習(Soft Actor-Critic 等)へ直結する伏線である。

7.4 方策オンとオフ、重点サンプリング

- **方策オン型 (on-policy)**: データを生成する方策(挙動方策)と、評価・改善する方策(目標方策)が同一。上記の ε -貪欲MC制御はこれ。
- **方策オフ型 (off-policy)**: 両者が異なる。例:探索的な方策 b でデータを集めながら、貪欲な目標方策 π を学習する。過去のデータや他者のデモの再利用ができるため実用上重要(続編のDQNの**経験再生**はまさに方策オフ性に依拠する)。

方策オフ型MCでは、分布のズレを**重点サンプリング (importance sampling)** で補正する。軌道 $\tau = (s_t, a_t, s_{t+1}, \dots, s_T)$ の生起確率の比は

$$\rho_{t:T-1} := \frac{\Pr_{\pi}(\tau)}{\Pr_b(\tau)} = \frac{\prod_{k=t}^{T-1} \pi(a_k | s_k) P(s_{k+1} | s_k, a_k)}{\prod_{k=t}^{T-1} b(a_k | s_k) P(s_{k+1} | s_k, a_k)} = \prod_{k=t}^{T-1} \frac{\pi(a_k | s_k)}{b(a_k | s_k)}$$

となる。**未知の遷移確率 P が分子分母で相殺して消える**ことが決定的に重要で、これにより比はモデルなしで計算できる。 $V^{\pi}(s) = \mathbb{E}_b[\rho_{t:T-1} G_t | S_t = s]$ として不偏推定できるが、比が多数の因子の積であるため**分散が指数的に増大しうる**のが泣きどころである。分散と引き換えに正規化でバイアスを許す加重重点サンプリングなどの工夫があるが、根本的には「長い軌道全体を一括で補正する」MCの構造に起因する問題であり、次章のTD学習(1ステップずつ補正・更新する)への動機の一つとなる。

🔄 物理との対応

重点サンプリングは、統計物理で分布 p の期待値を別の分布 q からのサンプルで計算する再重み付け ($\langle O \rangle_p = \langle O p/q \rangle_q$) と同一の手法であり、分散爆発の問題(オーバーラップ問題)も共通である。

7.5 MC法の特徴の整理

- 長所: 不偏推定。ブートストラップ(後述)をしないため、関数近似やマルコフ性の破れに対して頑健。実際に得た収益のみを使う。
- 短所: エピソード終端まで待たないと更新できない(継続タスクに使えない/学習が遅い)。収益 G_t は多数ステップの確率的な報酬の和なので**分散が大きい**。

「不偏だが高分散、更新が遅い」——この短所を、バイアスを許容する代わりに解消するのがTD学習である。

第8章 時間差分 (TD) 学習 — SARSAとQ学習

8.1 着想: ブートストラップ — 推定値で推定値を更新する

MC法の更新(7.1)の目標値は実収益 G_t だった。ここでBellman方程式に立ち返る。式(2.1) $G_t = R_{t+1} + \gamma G_{t+1}$ と、 $V^\pi(s') = \mathbb{E}[G_{t+1} | S_{t+1} = s']$ を思い出すと、 G_t の代わりに

$$R_{t+1} + \gamma \hat{V}(S_{t+1})$$

を目標値に使う、という発想が浮かぶ。将来の収益の実測値 G_{t+1} を、**自分自身の現在の推定値 $\hat{V}(S_{t+1})$ で代用**するのである。これを**ブートストラップ (bootstrap)** と呼ぶ。得られる更新則が **TD(0)** である:

🔗 アルゴリズム 8.1(TD(0) 方策評価)

遷移 (S_t, R_{t+1}, S_{t+1}) を観測するたびに、

$$\hat{V}(S_t) \leftarrow \hat{V}(S_t) + \alpha \underbrace{\left[R_{t+1} + \gamma \hat{V}(S_{t+1}) - \hat{V}(S_t) \right]}_{=:\delta_t \text{ (TD誤差)}}$$

括弧内の量

$$\delta_t := R_{t+1} + \gamma \hat{V}(S_{t+1}) - \hat{V}(S_t)$$

を**TD誤差**と呼ぶ。これは「Bellman方程式の左右両辺の食い違いの、1サンプル版」である。実際、真の V^π においては $\mathbb{E}_\pi[\delta_t | S_t = s] = \mathbb{E}_\pi[R_{t+1} + \gamma V^\pi(S_{t+1}) | S_t = s] - V^\pi(s) = 0$ (Bellman方程式(3.1)そのもの)であり、TD(0)は「TD誤差の期待値がゼロになるまで推定値

を調整する」、すなわち**Bellman方程式をサンプルベースの逐次近似で解くアルゴリズム**だと分かる。

🔄 直観:予測の時間差分

TD誤差は「時刻 t に立てた予測 $\hat{V}(S_t)$ 」と「1ステップ分の現実 R_{t+1} を見た後の更新された予測 $R_{t+1} + \gamma \hat{V}(S_{t+1})$ 」の差、すなわち**連続する2時点の予測の差分**である(名前の由来)。「予測が時間とともに整合的であるように学習する」と言ってもよい。なお神経科学では、ドーパミンニューロンの位相性発火がTD誤差と定量的によく対応することが知られており、TD学習は生物の報酬学習のモデルとしても中心的である。

8.2 3つの推定法の統一的比較

これまでの3手法は、バックアップの仕方で明快に分類できる:

手法	目標値	期待値の扱い	深さ
動的計画法 (DP)	$\sum_a \pi \left[R + \gamma \sum_{s'} P \hat{V}(s') \right]$	モデルで厳密に (全幅)	1ステップ+ブートストラップ
モンテカルロ (MC)	G_t (実収益)	サンプル(1軌道)	終端まで(ブートストラップなし)
TD(0)	$R_{t+1} + \gamma \hat{V}(S_{t+1})$	サンプル(1遷移)	1ステップ+ブートストラップ

バイアス・バリエンス分解の観点が本質的である:

- MCの目標 G_t : 不偏だが、多ステップの確率性(行動・遷移・報酬)をすべて含むため**高分散**。
- TDの目標 $R_{t+1} + \gamma \hat{V}(S_{t+1})$: 1ステップ分の確率性しか含まないため**低分散**。しかし $\hat{V}$ が不正確な間は**バイアス**をもつ。

TDは「自分の(まだ間違っているかもしれない)推定に寄りかかる」というリスクを負う代わりに、各ステップで即座に更新でき、分散が小さく、経験的にしばしばMCより速く学習する。バイアスは学習が進んで $\hat{V} \rightarrow V^\pi$ となるにつれ消えていく。

中間形態: n ステップTDとTD(λ)。実は両者は連続的につながっている。 n ステップ先までは実報酬を使い、そこでブートストラップする目標

$$G_t^{(n)} := R_{t+1} + \gamma R_{t+2} + \cdots + \gamma^{n-1} R_{t+n} + \gamma^n \hat{V}(S_{t+n})$$

を使えば、 $n = 1$ がTD(0)、 $n \rightarrow \infty$ (終端まで)がMCである。さらに全 n の目標を重み $(1 - \lambda)\lambda^{n-1}$ で幾何平均した目標を使う手法が**TD(λ)**であり、 $\lambda \in [0, 1]$ がバイアス・バリエアンストレードオフを連続的に調節するダイヤルになる($\lambda = 0$ でTD(0)、 $\lambda = 1$ でMC)。適格度トレース (eligibility trace) という仕掛けで効率的にオンライン実装できるが、詳細は割愛する。この「多ステップ収益の混合」という考え方は、続編で扱うGAE (Generalized

Advantage Estimation) やRainbow中の multi-step learning として現代の手法にそのまま生きている。

8.3 確率近似としての正当化:Robbins–Monro条件

TD(0)のような「ノイズを含む更新の繰り返し」がなぜ真値に収束するのか。一般論として、方程式 $\mathbb{E}[F(\theta, \xi)] = 0$ (ξ はノイズ)の根を、サンプル ξ_k を使った反復

$$\theta_{k+1} = \theta_k + \alpha_k F(\theta_k, \xi_k)$$

で求める手法を**確率近似 (stochastic approximation)** と呼ぶ(Robbins–Monro, 1951)。収束のためのステップサイズの標準的な十分条件が

$$\sum_{k=0}^{\infty} \alpha_k = \infty, \quad \sum_{k=0}^{\infty} \alpha_k^2 < \infty$$

である(例: $\alpha_k = 1/k$)。第1条件は「どんなに遠い初期値からでも到達できるだけの総移動量」を、第2条件は「ノイズの累積分散が有限で、揺らぎがいずれ死ぬこと」を保証する。ノイズ平均後のダイナミクスが縮小写像(まさにBellman作用素!)であることと合わせて、**表形式TD(0)は、すべての状態が無限回訪問され上記条件を満たすステップサイズを使えば、確率1で V^{π} に収束することが証明できる。**第5章の縮小性が、ここでもアルゴリズムの土台として働いていることに注意してほしい。

三 物理との対応:Langevin動力学

確率近似はポテンシャル勾配+ノイズで駆動される過減衰Langevin方程式の離散版と見なせる。 $\sum \alpha_k^2 < \infty$ は「温度を時間とともに下げてゼロにする」ことに相当し、系は最終的にポテンシャルの底(=Bellman方程式の解)に沈む。

8.4 制御へ:SARSA(方策オン型TD制御)

GPIに従い、TDで Q を推定しながら ε -貪欲で改善する。状態価値のTD(0)をそのまま Q に焼き直すと、遷移 $(S_t, A_t, R_{t+1}, S_{t+1}, A_{t+1})$ (頭文字を並べて **SARSA**)を観測するたびに:

🔗 アルゴリズム 8.2(SARSA)

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)]$$

ここで A_{t+1} は現在の(ε -貪欲な)方策が実際に選んだ行動。行動選択は Q に対する ε -貪欲。

目標値に「実際に次にとった行動 A_{t+1} 」の Q 値を使うため、SARSAは**いま従っている探索込みの方策そのものの Q^{π}** を推定する方策オン型である。GLIE条件とRobbins–Monro条件のもとで $Q \rightarrow Q^*$ が示される。

8.5 Q学習(方策オフ型TD制御)

SARSAの目標値の $Q(S_{t+1}, A_{t+1})$ を、次状態で最良の行動の値 $\max_{a'} Q(S_{t+1}, a')$ に置き換える:

🔗 アルゴリズム 8.3(Q学習; Watkins, 1989)

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a') - Q(S_t, A_t) \right]$$

この一見小さな変更の意味は深い。目標値 $R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a')$ は、Bellman最適方程式(4.4)の右辺の1サンプル版である。つまり:

- **SARSAはBellman期待方程式(T^π の不動点 Q^π)を、Q学習はBellman最適方程式(T^* の不動点 Q^*)を、それぞれサンプルで解いている。**
- Q学習は、データを生成した方策が何であれ(十分な探索さえあれば)**直接 Q^* を推定する**。挙動方策と目標方策(貪欲方策)が分離した**方策オフ型**である。だからこそ、古いデータの再利用(経験再生)が正当化され、これが続編のDQNの根幹となる。

収束定理も同様に成り立つ:すべての (s, a) が無限回更新され、ステップサイズがRobbins-Monro条件を満たせば、Q学習は確率1で Q^* に収束する。証明の核はやはり T^* の γ -縮小性(定理5.2)である。

⚠️ 過大評価バイアス (maximization bias)

Q学習の目標に含まれる $\max_{a'} Q(S_{t+1}, a')$ には落とし穴がある。推定値 Q にノイズが乗っているとき、一般に

$$\mathbb{E} \left[\max_{a'} Q(s', a') \right] \geq \max_{a'} \mathbb{E} [Q(s', a')]$$

(最大値の期待値は期待値の最大以上; Jensen型の不等式)であり、**ノイズが正に選択されるため Q を系統的に過大評価する**。行動の「選択」に使う推定量と「評価」に使う推定量を独立な2系統に分ける **Double Q学習** がこの偏りを緩和する。続編で登場する Double DQN はこのアイデアの深層版である。

8.6 表形式手法の総括

ここまでで、**環境モデルなしに、経験のみから最適方策を学習する完全なアルゴリズム (SARSA・Q学習)** が手に入った。理論の系譜を振り返る:

1. Bellman方程式が価値の局所的整合条件を与え(第3-4章)、
2. 縮小写像の理論が反復解法の収束を保証し(第5章)、
3. DPがモデルありの反復解法を与え(第6章)、
4. 期待値をサンプル平均に置き換えることでモデルフリー化し(第7章)、
5. ブートストラップにより逐次的・低分散な学習則に到達した(第8章)。

残る最大の前提は「 V や Q を表(ルックアップテーブル)として保持できる」こと、すなわち状態空間が列挙可能なほど小さいことである。囲碁($\sim 10^{170}$ 状態)やカメラ画像を状態とする問題では絶望的に成り立たない。この壁を越えるのが関数近似であり、次章で扱う。

第9章 関数近似への入り口 — 表形式の限界を超える

9.1 動機と問題設定

表形式手法の限界は2つある:

1. **メモリと計算量:** 状態数が膨大(あるいは連続)だと、表を持つことすらできない。
2. **汎化の欠如:** 表の各エントリは独立に学習されるため、「似た状態は似た価値をもつはず」という構造を利用できない。一度も訪れていない状態については何も言えない。

そこで、価値関数をパラメータ $\mathbf{w} \in \mathbb{R}^d (d \ll |\mathcal{S}|)$ をもつ関数族で近似する:

$$\hat{v}(s; \mathbf{w}) \approx V^\pi(s)$$

これで問題は「 $|\mathcal{S}|$ 個の値を覚える」ことから「 d 個のパラメータを調整する」ことに変わり、汎化(あるパラメータ更新が多くの状態の予測を同時に動かすこと)が自動的に得られる。物理でいえば、多体系の状態を有限個の秩序パラメータ・変分パラメータで記述する変分近似への移行である。

9.2 目的関数と勾配

何を最小化すべきか。自然な選択は、状態の重要度分布 $\mu(s)$ (典型的には方策 π のもとでの訪問頻度)で重みづけた二乗誤差:

$$J(\mathbf{w}) = \frac{1}{2} \sum_s \mu(s) [V^\pi(s) - \hat{v}(s; \mathbf{w})]^2 = \frac{1}{2} \mathbb{E}_{s \sim \mu} [(V^\pi(s) - \hat{v}(s; \mathbf{w}))^2]$$

確率的勾配降下 (SGD) では、訪問した状態 S_t ごとに1サンプルの勾配で更新する:

$$\mathbf{w} \leftarrow \mathbf{w} + \alpha [V^\pi(S_t) - \hat{v}(S_t; \mathbf{w})] \nabla_{\mathbf{w}} \hat{v}(S_t; \mathbf{w})$$

もちろん真値 $V^\pi(S_t)$ は未知なので、これまでと同じく目標値で置き換える:

- **MC版:** 目標 $= G_t$ 。 $\mathbb{E}[G_t | S_t] = V^\pi(S_t)$ なので、これは真の目的関数の不偏なSGDであり、(通常の条件下で)局所最適に収束する。
- **TD版(semi-gradient TD(0)):** 目標 $= R_{t+1} + \gamma \hat{v}(S_{t+1}; \mathbf{w})$ 。更新則は

$$\mathbf{w} \leftarrow \mathbf{w} + \alpha [R_{t+1} + \gamma \hat{v}(S_{t+1}; \mathbf{w}) - \hat{v}(S_t; \mathbf{w})] \nabla_{\mathbf{w}} \hat{v}(S_t; \mathbf{w})$$

⚠ 「semi-gradient(準勾配)」の意味

TD版の目標値 $R_{t+1} + \gamma \hat{v}(S_{t+1}; \mathbf{w})$ は**それ自身が $\mathbf{w}$ に依存する**。真の勾配をとるなら目標側の $\nabla_{\mathbf{w}} \hat{v}(S_{t+1}; \mathbf{w})$ の項も現れるはずだが、上の更新則はそれを**意図的に無視**している(目標を定数扱いする)。だから「準」勾配である。これは単なる手抜きではなく、「目標は教師信号として固定し、予測側だけを目標に近づける」というブートストラップの哲学の帰結だが、代償として**もはや何らかの目的関数の勾配ではなくなり、一般には収束保証が崩れる**。続編で学ぶDQNの「ターゲットネットワーク」(目標側のパラメータを一定期間凍結する仕掛け)は、この論点への実装的な応答である。

9.3 線形関数近似

理論が最もよく分かるのは**線形**の場合である。状態の**特徴ベクトル** $\phi(s) \in \mathbb{R}^d$ を設計し、

$$\hat{v}(s; \mathbf{w}) = \mathbf{w}^\top \phi(s), \quad \nabla_{\mathbf{w}} \hat{v}(s; \mathbf{w}) = \phi(s)$$

とする。semi-gradient TD(0)の更新は

$$\mathbf{w} \leftarrow \mathbf{w} + \alpha \delta_t \phi(S_t), \quad \delta_t = R_{t+1} + \gamma \mathbf{w}^\top \phi(S_{t+1}) - \mathbf{w}^\top \phi(S_t)$$

表形式は $\phi(s) = \mathbf{e}_s$ (one-hotベクトル) という特殊ケースとして含まれることを確認してほしい。この意味で、第7-8章までの理論はすべて線形近似の特別な場合だったのである。

収束の性質(結果のみ): 方策オン型(状態分布 μ が π の定常分布)の線形semi-gradient TD(0) は、一意な不動点 $\mathbf{w}_{\text{TD}}$ に収束することが証明できる。ただし収束先は二乗誤差 J の最小点 $\mathbf{w}^{\text{MC}}$ そのものではなく、誤差の上界

$$\overline{\text{VE}}(\mathbf{w}_{\text{TD}}) \leq \frac{1}{1-\gamma} \min_{\mathbf{w}} \overline{\text{VE}}(\mathbf{w})$$

を満たす点である(射影Bellman作用素の不動点。近似族の表現力の限界内での最良解の $\frac{1}{1-\gamma}$ 倍以内)。証明には、定常分布 μ による重みづけノルムのもとで「 P^π による1ステップ発展 + 特徴空間への直交射影」の合成が縮小写像になる、という第5章の議論の精緻化を使う。

9.4 死の三つ組 (The Deadly Triad)

上記の収束保証は、実は絶妙なバランスの上に成り立っている。次の3要素が**同時に**揃うと、価値推定が発散する例が構成できることが知られている:

1. **関数近似**(表形式でない)
2. **ブートストラップ**(TDのように推定値を目標に使う)
3. **方策オフ学習**(更新に使う状態分布が目標方策の定常分布と異なる)

これを **deadly triad(死の三つ組)** と呼ぶ。直観的には:ブートストラップは「目標が自分の推定に依存する」自己言及構造をもち、関数近似は「1つの更新が他の状態の値を勝手に動かす」波及をもたらし、方策オフ性は「どの状態の誤差を重視するか」の重み μ を縮小性の

証明が要求するものからずらす。3つが噛み合うと、正のフィードバックループが生じて推定が発散しうる。

🔄 続編への最重要の伏線

深層強化学習の代表格DQNは、まさに「非線形関数近似(深層ネット)+ブートストラップ(Q学習)+方策オフ(経験再生)」であり、**deadly triadのすべてを踏んでいる**。それでも動くのは、経験再生によるデータの脱相関、ターゲットネットワークによる自己言及の緩和、報酬クリッピング等の工夫が不安定性を実用上抑え込んでいるからである。続編では、これらの工夫を「本章で学んだ不安定性の理論への処方箋」として読み解くことになる。本章の内容は、深層強化学習が「なぜ壊れやすく、どこに注意すべきか」を理解するための土台である。

第10章 方策勾配法 — 方策を直接最適化する

10.1 発想の転換:価値ベースから方策ベースへ

ここまでの制御手法(Q学習など)はすべて「価値関数を学習し、それに貪欲な方策を導く」価値ベースの方法だった。本章では発想を転換し、**方策そのものをパラメータ化して、期待収益を直接最大化する**：

$$\pi_{\theta}(a \mid s), \quad \theta \in \mathbb{R}^d$$

例:softmax方策 $\pi_{\theta}(a|s) \propto \exp(\theta^{\top} \phi(s, a))$ 、連続行動ならガウス方策 $\pi_{\theta}(a|s) = \mathcal{N}(a; \mu_{\theta}(s), \sigma_{\theta}^2(s))$ など。

目的関数は、初期状態分布 ρ_0 のもとでの期待収益:

$$J(\theta) := \mathbb{E}_{s_0 \sim \rho_0} [V^{\pi_{\theta}}(s_0)]$$

これを勾配上昇 $\theta \leftarrow \theta + \alpha \nabla_{\theta} J$ で最大化したい。方策ベースの利点:

- **連続・高次元の行動空間**を自然に扱える($\max_a$ の計算が不要。ロボット制御などで決定的)。
- **確率の方策そのもの**を学習できる(部分観測環境などでは確率の方策が最適になりうる)。
- 方策パラメータの微小変化は行動確率の微小変化を生むだけなので、価値ベースの「 $\arg \max$ が不連続に切り替わる」挙動より学習が滑らかになりやすい。

問題は $\nabla_{\theta} J$ の計算である。 J への θ の影響は、「各状態での行動選択」を通じてだけでなく、「その結果どの状態を訪れるようになるか(状態分布の変化)」を通じても現れる。後者は環境モデル P に依存するから、一見、勾配の計算にはモデルが必要に思える。**実はそうではない**、というのが次の定理の驚きである。

10.2 方策勾配定理の導出

以下、記述を簡潔にするため $\pi = \pi_\theta$ 、 $\nabla = \nabla_\theta$ と書く。方針: $\nabla V^\pi(s)$ の再帰式を作り、それを展開(unroll)する。

Step 1: ∇V^π の再帰式。 式(2.2)と(3.2)より $V^\pi(s) = \sum_a \pi(a|s) Q^\pi(s, a)$ 。積の微分で

$$\nabla V^\pi(s) = \sum_a [\nabla \pi(a|s) Q^\pi(s, a) + \pi(a|s) \nabla Q^\pi(s, a)]$$

第2項の ∇Q^π に式(3.2) $Q^\pi(s, a) = R(s, a) + \gamma \sum_{s'} P(s'|s, a) V^\pi(s')$ を使うと、 R と P は θ に依存しないから

$$\nabla Q^\pi(s, a) = \gamma \sum_{s'} P(s'|s, a) \nabla V^\pi(s')$$

まとめて、便利な略記 $g(s) := \sum_a \nabla \pi(a|s) Q^\pi(s, a)$ を導入すると:

$$\nabla V^\pi(s) = g(s) + \gamma \sum_{s'} P^\pi(s' | s) \nabla V^\pi(s') \quad (10.1)$$

ここで $P^\pi(s'|s) = \sum_a \pi(a|s) P(s'|s, a)$ (1.4節)。**式(10.1)は ∇V^π 自身に関するBellman型の線形方程式**であることに注目。「ソース項 g + 割引つき伝播」という、第3章で見たのと同じ構造である。

Step 2: 展開。 第3章のNeumann級数(3.6)と全く同様に、(10.1)を反復代入して解く:

$$\nabla V^\pi(s) = \sum_{k=0}^{\infty} \gamma^k \sum_x \Pr(S_k = x | S_0 = s; \pi) g(x)$$

($\Pr(S_k = x | S_0 = s; \pi)$ は $(P^\pi)^k$ の (s, x) 成分。)初期分布 ρ_0 で平均し、**割引訪問頻度**

$$d^\pi(x) := \sum_{k=0}^{\infty} \gamma^k \Pr(S_k = x | S_0 \sim \rho_0; \pi)$$

を定義すると(これは正規化すれば分布になる;規格化定数は $\sum_x d^\pi(x) = \frac{1}{1-\gamma}$)、次を得る:

 **定理 10.1(方策勾配定理; Sutton et al., 2000)**

$$\nabla_\theta J(\theta) = \sum_s d^\pi(s) \sum_a \nabla_\theta \pi_\theta(a | s) Q^\pi(s, a)$$

この定理の要点: 右辺に**状態分布 d^π の勾配 ∇d^π が現れない**。方策の変化が将来の状態訪問分布を変える効果は確かに存在するのに、勾配の式には(すでに d^π の中に織り込まれた形でしか)現れず、明示的に微分する必要がないのである。これにより、環境モデルなしで勾配が推定できる道が開ける。

Step 3: 期待値の形へ(log-derivative trick)。 サンプルで推定できる形に書き換える。恒等式

$$\nabla \pi(a|s) = \pi(a|s) \frac{\nabla \pi(a|s)}{\pi(a|s)} = \pi(a|s) \nabla \ln \pi(a|s)$$

を使うと、 $\sum_a \pi(a|s)(\cdot)$ が期待値 $\mathbb{E}_{a \sim \pi}$ になり、

$$\nabla_{\theta} J \propto \mathbb{E}_{s \sim d^{\pi}, a \sim \pi_{\theta}(\cdot|s)} [\nabla_{\theta} \ln \pi_{\theta}(a | s) Q^{\pi}(s, a)] \quad (10.2)$$

方策 π_{θ} に従って行動しているとき、訪れる状態・行動はまさに d^{π}, π からのサンプルになっているので、(10.2)の中身をサンプルで置き換えれば不偏な勾配推定量が得られる。統計力学・場の理論で頻出の $\nabla Z = Z \nabla \ln Z$ 型の恒等式(スコア関数)がここでも主役である。

10.3 REINFORCE

残る未知量は $Q^{\pi}(s, a)$ だが、これは前章までの知見でどうにでもなる。最も単純なのはMC推定: $Q^{\pi}(S_t, A_t) = \mathbb{E}[G_t | S_t, A_t]$ なので、実収益 G_t で置き換えればよい。

🔗 アルゴリズム 10.2(REINFORCE; Williams, 1992)

方策 π_{θ} でエピソードを生成し、各時刻 t について

$$\theta \leftarrow \theta + \alpha \gamma^t G_t \nabla_{\theta} \ln \pi_{\theta}(A_t | S_t)$$

(γ^t の因子は割引訪問頻度 d^{π} に由来する。実用上はしばしば省略される。)

直観: $\nabla \ln \pi(A_t | S_t)$ は「行動 A_t の対数確率を最も増やすパラメータ方向」。それを収益 G_t で重みづけるので、**良い結果につながった行動の確率は上がり、悪い結果につながった行動の確率は下がる(あるいは相対的に抑えられる)**。試行錯誤による学習の、最も素直な数学的表現である。

10.4 ベースライン — 分散低減の理論

REINFORCEは不偏だが、MCベースゆえ勾配推定の分散が非常に大きい。決定的な改善が**ベースライン**の導入である: 収益から状態のみに依存する任意の関数 $b(s)$ を引く。

$$\theta \leftarrow \theta + \alpha \gamma^t [G_t - b(S_t)] \nabla_{\theta} \ln \pi_{\theta}(A_t | S_t)$$

不偏性が保たれることの証明: 追加された項の期待値がゼロであることを示せばよい。各状態 s で、

$$\sum_a \pi(a|s) \nabla \ln \pi(a|s) b(s) = b(s) \sum_a \nabla \pi(a|s) = b(s) \nabla \underbrace{\sum_a \pi(a|s)}_{=1} = b(s) \cdot \mathbf{0} = \mathbf{0}$$

確率の規格化条件の微分がゼロであること、および b が行動 a に依存しないこと(だから和の外に出せる)だけを使った。■

一方、 b の選び方は分散には効く。分散を最小化する b はおよそ状態価値 $V^{\pi}(s)$ であることが示せ、このとき勾配の重みは

$$G_t - V^{\pi}(S_t) \approx Q^{\pi}(S_t, A_t) - V^{\pi}(S_t) = A^{\pi}(S_t, A_t)$$

すなわち**アドバンテージ関数**(2.3節)になる。直観的には:重みが「収益の絶対値」だと、たとえばすべての報酬が正の環境ではどの行動も強化されてしまい、差がノイズに埋もれる。「その状態の平均と比べてどれだけ良かったか」という**相対評価**にすることで、系統的なオフセットが除去され、シグナルだけが残る。物理の言葉でいえば、期待値まわりの揺らぎ(キュムラント)だけを見る、という常套手段である。

10.5 アクター・クリティックへ

ベースライン $b(s) \approx V^\pi(s)$ を、どう手に入れるか?——第8章で学んだTD学習で、パラメトリックな価値関数 $\hat{v}(s; \mathbf{w})$ として**同時に学習すればよい**。さらに、勾配の重み $G_t - \hat{v}(S_t)$ のMC収益 G_t をTD目標 $R_{t+1} + \gamma \hat{v}(S_{t+1}; \mathbf{w})$ で置き換えれば(バイアスと引き換えの分散低減:8.2節の議論の再演)、重みは**TD誤差そのもの**になる:

$$\delta_t = R_{t+1} + \gamma \hat{v}(S_{t+1}; \mathbf{w}) - \hat{v}(S_t; \mathbf{w})$$

$$\text{方策(アクター): } \boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha_\theta \delta_t \nabla_{\boldsymbol{\theta}} \ln \pi_{\boldsymbol{\theta}}(A_t | S_t)$$

$$\text{価値(クリティック): } \mathbf{w} \leftarrow \mathbf{w} + \alpha_w \delta_t \nabla_{\mathbf{w}} \hat{v}(S_t; \mathbf{w})$$

これが**アクター・クリティック (actor-critic)** 法である。行動する主体(アクター=方策)と、それを批評する主体(クリティック=価値関数)が、同じTD誤差 δ_t を共有して同時に学習する。TD誤差が正なら「予想より良かった → その行動を強化」、負なら逆。本テキストで築いた2本の柱——**価値ベースの学習(第3-8章)**と**方策ベースの学習(本章)**——がここで合流する。

🔗 続編への接続

アクター・クリティックの関数近似器を深層ニューラルネットに置き換え、分散計算・分散低減・更新の安定化の工夫を重ねたものが、A2C/A3C、GAE、TRPO、PPO、SACといった現代の主要アルゴリズム群である。特にPPOで中心となる「方策更新の大きさを制約する」という発想は、本章の勾配法が「 d^π が方策とともに動くため、古いデータで大きく更新すると勾配推定的前提が崩れる」という構造的弱点をもつことへの応答であり、本章を理解していれば動機が明確に見えるはずである。

第11章 総括と展望 — 深層強化学習へ

11.1 本テキストの論理構造の総復習

本テキストで辿った道を、一つの図式にまとめる。

MDP の定義 (第1章)

└ マルコフ性 $\Rightarrow$ 収益の再帰式 $G_t = R_{t+1} + \gamma G_{t+1}$ (第2章)

└ 期待値をとる $\Rightarrow$ Bellman期待方程式 / 最適方程式 (第3-4章)

└ 作用素の γ -縮小性 $\Rightarrow$ 解の存在・一意性・反復収束・最適方策の存在 (第5

章)

- └ モデル既知: 反復を厳密に実行 ⇒ 方策反復・価値反復 (第6章)
- └ モデル未知: 期待値をサンプルで近似
 - └ 軌道全体で ⇒ モンテカルロ法 (第7章)
 - └ 1遷移+ブートストラップ ⇒ TD / SARSA / Q学習 (第8章)
 - └ 状態空間が巨大: 関数近似 (第9章)
 - └ 方策を直接パラメータ化 ⇒ 方策勾配・actor-critic (第10章)

すべての根はBellman方程式の再帰構造と縮小性にあり、各アルゴリズムは「期待値の計算をどの程度厳密に/どの深さで/どの分布のデータで行うか」の設計選択にすぎない——この統一的視点こそが、本テキストで持ち帰ってほしい最大の成果である。

11.2 深層強化学習への地図

続編で扱う内容は、本テキストの各章と次のように対応する:

続編の話題	本テキストの土台
DQN (深層Qネットワーク)	Q学習(8.5節)+ 非線形関数近似(第9章)。経験再生は方策オフ性(7.4, 8.5節)、ターゲットネットワークはsemi-gradientの自己言及問題(9.2節)、不安定性の理解は deadly triad(9.4節)に対応
Double DQN / Dueling / Rainbow	過大評価バイアスとDouble Q学習(8.5節)、 V と A の分解(2.3節)、 n -step収益(8.2節)
A2C / A3C, GAE	アクター・クリティック(10.5節)、TD(λ)型のバイアス・バリエンス調節(8.2節)
TRPO / PPO	方策勾配定理(10.2節)と、方策更新に伴う状態分布のずれの問題(10.5節)。信頼領域の議論には方策改善定理(6.2節)の一般化(性能差分補題)が使われる
SAC / 最大エントロピーRL	Boltzmann方策(7.3節)。Bellman方程式にエントロピー項を加えた「ソフトBellman方程式」も同様の縮小性で解析される(第5章の手法がそのまま再登場する)
モデルベースRL / AlphaZero系	動的計画法とプランニング(第6章)、価値のバックアップと探索の統合

読者は続編に進む際、新しい手法に出会うたびに「GPI(6.5節)のどの部品か」「deadly triad(9.4節)のどれを踏んでいて、どう対処しているか」「勾配の不偏性と分散(第10章)をどう天秤にかけているか」の3点を問うてほしい。それだけで、深層強化学習の一見雑多な手法群が、本テキストの理論の必然的な発展形として整理されて見えるはずである。

11.3 参考文献案内

- R. S. Sutton & A. G. Barto, *Reinforcement Learning: An Introduction* (2nd ed., MIT Press, 2018) — 標準的教科書。本テキストの記法は概ねこれに従った。

- D. P. Bertsekas, *Dynamic Programming and Optimal Control* — 動的計画法の数学的に厳密な体系書。
- Cs. Szepesvári, *Algorithms for Reinforcement Learning* — 収束証明を含む簡潔な理論的モノグラフ。
- M. L. Puterman, *Markov Decision Processes* — MDP理論の決定版。

付録A Banachの不動点定理の証明

🔗 定理(再掲)

(X, d) を完備距離空間、 $T: X \rightarrow X$ を係数 $\gamma \in [0, 1)$ の縮小写像とする。このとき T は一意の不動点 x^* をもち、任意の x_0 から $x_{k+1} = Tx_k$ は x^* に収束し、
 $d(x_k, x^*) \leq \gamma^k d(x_0, x^*)$ 。

証明。

(1) 反復列がCauchy列であること。まず隣接項間の距離は縮小性の反復適用により

$$d(x_{k+1}, x_k) = d(Tx_k, Tx_{k-1}) \leq \gamma d(x_k, x_{k-1}) \leq \cdots \leq \gamma^k d(x_1, x_0)$$

$m > n$ に対し、三角不等式と幾何級数の和より

$$d(x_m, x_n) \leq \sum_{k=n}^{m-1} d(x_{k+1}, x_k) \leq \sum_{k=n}^{m-1} \gamma^k d(x_1, x_0) \leq \frac{\gamma^n}{1-\gamma} d(x_1, x_0) \xrightarrow{n \rightarrow \infty} 0$$

よって $\{x_k\}$ はCauchy列であり、完備性から極限 $x^* = \lim_k x_k \in X$ が存在する。

(2) 極限が不動点であること。縮小写像は連続(Lipschitz連続)なので、

$$Tx^* = T\left(\lim_k x_k\right) = \lim_k Tx_k = \lim_k x_{k+1} = x^*$$

(3) 一意性。 x^*, y^* がともに不動点なら

$$d(x^*, y^*) = d(Tx^*, Ty^*) \leq \gamma d(x^*, y^*)$$

$\gamma < 1$ より $d(x^*, y^*) = 0$ 、すなわち $x^* = y^*$ 。

(4) 収束レート。 $d(x_k, x^*) = d(Tx_{k-1}, Tx^*) \leq \gamma d(x_{k-1}, x^*) \leq \cdots \leq \gamma^k d(x_0, x^*)$ 。 ■

付録B 連続時間極限とHamilton-Jacobi-Bellman方程式

物理学の読者のために、Bellman最適方程式の連続時間極限を素描する。決定論的ダイナミクス $\dot{x} = f(x, u)$ (x : 状態、 u : 制御入力)、報酬率 $r(x, u)$ 、割引率 $e^{-\rho t}$ の最適制御問題

$$V^*(x) = \max_{u(\cdot)} \int_0^\infty e^{-\rho t} r(x(t), u(t)) dt, \quad x(0) = x$$

を考える。微小時間 Δt に対する離散化でBellman最適方程式は

$$V^*(x) = \max_u \left[r(x, u) \Delta t + e^{-\rho \Delta t} V^*(x + f(x, u) \Delta t) \right] + o(\Delta t)$$

右辺を Δt の1次まで展開する: $e^{-\rho \Delta t} \approx 1 - \rho \Delta t$ 、 $V^*(x + f \Delta t) \approx V^*(x) + \nabla V^* \cdot f \Delta t$ より

$$V^*(x) = \max_u [r \Delta t + V^*(x) + (\nabla V^* \cdot f - \rho V^*) \Delta t] + o(\Delta t)$$

両辺から $V^*(x)$ を消去し Δt で割って $\Delta t \rightarrow 0$ とすると、**Hamilton-Jacobi-Bellman (HJB) 方程式**を得る:

$$\rho V^*(x) = \max_u [r(x, u) + \nabla V^*(x) \cdot f(x, u)]$$

右辺の被最大化量は、共役運動量を $p = \nabla V^*$ と同一視すれば(制御理論の)Hamiltonian

$\mathcal{H}(x, p, u) = r + p \cdot f$ であり、HJB方程式は古典力学のHamilton-Jacobi方程式

$\partial_t S + \mathcal{H}(x, \nabla S) = 0$ の最適制御版に他ならない。**価値関数はHamiltonの主関数(作用)の、**

Bellman方程式は最小作用の原理の、それぞれ意思決定理論における対応物である。確率的なダイナミクス(拡散項)を入れると右辺に二階微分項(伊藤の補題由来)が加わり、HJBは二階の非線形偏微分方程式になる。この視点は、連続制御を扱う深層強化学習(DDPG、SAC等)の背景理解にも役立つ。

付録C 記法一覧

記号	意味
$\mathcal{S}, \mathcal{A}$	状態空間・行動空間
S_t, A_t, R_t	時刻 t の状態・行動・報酬(確率変数)
$P(s' s, a)$	状態遷移確率
$R(s, a)$	期待即時報酬
γ	割引率($0 \leq \gamma < 1$)
$\pi(a s)$	方策(状態→行動分布)
P^π, R^π	方策で平均した遷移行列・報酬ベクトル
G_t	時刻 t からの割引収益
$V^\pi(s), Q^\pi(s, a)$	方策 π の状態価値・行動価値
$V^*(s), Q^*(s, a)$	最適状態価値・最適行動価値
$A^\pi(s, a)$	アドバンテージ関数 $Q^\pi - V^\pi$
T^π, T^*	Bellman期待作用素・最適作用素
δ_t	TD誤差 $R_{t+1} + \gamma \hat{V}(S_{t+1}) - \hat{V}(S_t)$

記号	意味
α	学習率(ステップサイズ)
ε	ε -貪欲方策の探索率
w, θ	価値関数・方策のパラメータ
$\phi(s)$	状態の特徴ベクトル
$d^\pi(s)$	割引状態訪問頻度
$\ v\ _\infty$	supノルム $\max_s$

〰 結び

Bellman方程式とは、「全体の最適性は局所の整合性の積み重ねとして特徴づけられる」という一つの原理の表現である。この原理は、最小作用の原理が力学を貫くのと
同じように、強化学習のあらゆる場所——価値反復からQ学習、そして深層強化学習の
最前線まで——を貫いている。続編では、この骨格に深層ニューラルネットワークと
いう筋肉をまとわせていく。理論の背骨は、もう読者の手の中にある。