

強化学習の数理_4_演習_実践コーディング編

強化学習演習 実践コーディング編 — アルゴリズムを自分の環境で動かす

🔗 シリーズ全体の目次

- [強化学習の数理 1 基礎編](#) — 古典的RL理論(MDP・Bellman方程式・DP・TD・方策勾配)
- [強化学習の数理 2 深層学習編](#) — 深層強化学習(DQN・A2C・PPO・SAC等)
- [強化学習の数理 3 演習 手計算編](#) — 上記2冊の導出を手計算で再構成する演習
- [強化学習の数理 4 演習 実践コーディング編](#)(本稿) — 上記2冊のアルゴリズムをコードで実装する演習

📖 本演習テキストについて

本テキストは、解説テキスト [強化学習の数理 1 基礎編](#) と [強化学習の数理 2 深層学習編](#) に登場するアルゴリズムを、標準的なローカル環境(Python + NumPy + Matplotlib のみ)で実装・実行して理論を体感するための課題集である。

- 各課題は「ステップ」に分割しており、**上から順に実装すれば必ず動くところまで到達できるように**書いてある。骨格コードの `# TODO` を埋めるのが基本作業である。
- 各課題末尾の `[!check]` 確認ポイント に、正しく実装できたときに得られるはずの**具体的な数値・挙動**を示した。理論値と照合すること。
- 環境(GridWorld等)もすべて自作する。外部の強化学習ライブラリ・GPU・深層学習フレームワークは不要である。
- 深層強化学習のうち、ローカル再現が難しい要素(Atari規模のDQN、連続制御のDDPG/TD3/SAC、MCTS/AlphaZero、RLHF)は、**本質を保った縮小版**(課題11・13・14)に置き換えるか、対象外とした。対応関係は各課題の冒頭に記す。
- 式の導出そのものを確認したくなったら、姉妹編 [強化学習の数理 3 演習 手計算編](#) の対応問題へ。

🔗 準備

Python 3.9以降で以下が動けばよい。

```
pip install numpy matplotlib
```

各課題は独立した1つの `.py` ファイル(または1つのノートブックセル群)として書ける規模である。乱数は `rng = np.random.default_rng(0)` のようにシードを固定して再現性を確保すること。

課題1 2状態MDP:厳密解・反復解・収束レート γ

対応理論: [強化学習の数理 1 基礎編 > 第3章 Bellman期待方程式 — 価値の自己無撞着方程式 3.3節](#)、[強化学習の数理 1 基礎編 > 第5章 Bellman作用素と不動点定理 — 理論の心臓部](#)、6.6節の2状態MDP。手計算では [強化学習の数理 3 演習 手計算編](#) 問題4・6・7。

目的: Bellman期待方程式が (a) 逆行列で厳密に解け、(b) 作用素の反復でも解け、(c) 反復の誤差が正確に γ^k で減衰する、ことを1つの画面で確認する。

ステップ1 環境の定義

解説テキスト6.6節の2状態MDP($\gamma = 0.9$)を配列で表現する。

```
import numpy as np
import matplotlib.pyplot as plt

gamma = 0.9
# 状態 0 = s1, 1 = s2 / 行動 0 = stay, 1 = move
R = np.array([[1.0, 0.0],
               [2.0, 0.0]])      # R[s, a]
NXT = np.array([[0, 1],
                 [1, 0]])      # 決定論的遷移: NXT[s, a] = 次状態
```

ステップ2 方策評価:厳密解

方策 π_0 = 「常に stay」について、 P^{π_0} (2×2 行列) と r^{π_0} を作り、

$$\boldsymbol{v}^{\pi_0} = (I - \gamma P^{\pi_0})^{-1} \boldsymbol{r}^{\pi_0}$$

を `np.linalg.solve` で計算せよ。

```
def eval_exact(policy):      # policy[s] = 行動
    P = np.zeros((2, 2)); r = np.zeros(2)
    for s in range(2):
        a = policy[s]
        P[s, NXT[s, a]] = 1.0    # 決定論的遷移
        r[s] = R[s, a]
    return np.linalg.solve(np.eye(2) - gamma * P, r)

print(eval_exact([0, 0]))    # 常にstay
```

ステップ3 反復的方策評価と収束レートの実測

同じ方策を $v_0 = \mathbf{0}$ から $v_{k+1} = T^\pi v_k$ で解き、各反復の誤差 $\|v_k - v^\pi\|_\infty$ を記録して片対数プロットせよ。隣接誤差の比 $\text{err}[k+1]/\text{err}[k]$ も表示すること。

ステップ4 価値反復で最適方策へ

$v_{k+1}(s) = \max_a [R(s, a) + \gamma v_k(\text{NXT}[s, a])]$ を実装し、 V^* と、それに貪欲な方策を出力せよ。ステップ3と同様に $\|v_k - V^*\|_\infty$ の減衰も記録する。

✓ 確認ポイント

- 厳密解: 「常に stay」で $V = (10, 20)$ 、最適で $V^* = (18, 20)$ 、最適方策は $\pi^*(s_1) = \text{move}$, $\pi^*(s_2) = \text{stay}$ (解説テキスト6.6節の手計算と一致)。
- 誤差の片対数プロットが直線になり、隣接誤差比が 0.900 にほぼ一致する (数反復目以降)。定理5.5の幾何収束レート γ^k の実証である。
- `gamma = 0.99` に変えると直線の傾きが緩くなり、同じ精度に要する反復回数が約10倍になる (手計算編 問6.5)。

課題2 4×4 GridWorldで方策反復と価値反復

対応理論: [強化学習の数理 1 基礎編 > 第6章 動的計画法 — モデルが既知のときの厳密解法](#)。

目的: 状態数16の小さな世界で、GPIの2つの極(方策反復・価値反復)を両方実装し、同じ最適解に到達することを確認する。

ステップ1 環境:4×4グリッド

- 状態 0~15 (左上0、右下15を行優先で番号づけ)。0 と 15 が終端。
- 行動: 上/下/左/右。壁にぶつくとその場に留まる。
- 報酬: 終端以外での全遷移で -1 (「早くゴールせよ」)。 $\gamma = 1$ (エピソード的タスクなので許される)。

```
N = 16; TERM = (0, 15); ACTIONS = range(4)
```

```
def step(s, a):
    if s in TERM: return s, 0.0
    r, c = divmod(s, 4)
    if a == 0: r = max(r - 1, 0)
    elif a == 1: r = min(r + 1, 3)
    elif a == 2: c = max(c - 1, 0)
```

```
else:      c = min(c + 1, 3)
return r * 4 + c, -1.0
```

ステップ2 一様ランダム方策の反復的方策評価

$\pi(a|s) = 1/4$ を、同期更新で max 差分が 10^{-8} を切るまで評価し、`V.reshape(4,4)` を丸めて表示せよ。

ステップ3 方策反復

評価(ステップ2の関数を任意の方策に一般化)と貪欲化を交互に回し、方策が変化しなくなるまで反復。何回の改善で停止したかを表示せよ。

ステップ4 価値反復

$v_{k+1}(s) = \max_a [r + v_k(s')]$ を回し、方策反復と同じ V^* ・同じ貪欲方策に達することを確認せよ。

✓ 確認ポイント

- ランダム方策の価値(収束値、丸めて整数):

```
[[ 0. -14. -20. -22.]
 [-14. -18. -20. -20.]
 [-20. -20. -18. -14.]
 [-22. -20. -14.  0.]]
```

対称性(180°回転で不変)が出ていれば実装はほぼ正しい。

- 最適価値:

```
[[ 0. -1. -2. -3.]
 [-1. -2. -3. -2.]
 [-2. -3. -2. -1.]
 [-3. -2. -1.  0.]]
```

= 「最寄りの終端までの最短手数の符号反転」。

- 方策反復はごく少数回(高々3回程度)の改善で停止する。「改善停止 $\Leftrightarrow$ 最適到達」(手計算編 問8.4)の実演。

課題3 モンテカルロ方策評価: サンプル平均は $1/\sqrt{N}$ で収束する

対応理論: [強化学習の数理 1 基礎編 > 第7章 モンテカルロ法 — モデルフリー学習への第一歩](#)。手計算では [強化学習の数理 3 演習 手計算編](#) 問題9.1。

目的: モデル (P, R) を一切使わず、軌道サンプルだけから価値を推定できること、およびその統計的収束の速さを体感する。

ステップ1 環境:5状態ランダムウォーク

状態 $1, \dots, 5$ を一列に並べ、両端の外(0 と 6)が終端。方策は「左右へ確率 $1/2$ ずつ」。右端終端に到達したときのみ報酬 $+1$ 、それ以外は 0 。 $\gamma = 1$ 。開始状態は中央の 3 。

真の価値は $V^\pi(k) = k/6 (k = 1, \dots, 5)$ であることが知られている(右端に先に到達する確率。対称ランダムウォークの吸収確率)。

ステップ2 first-visit MC

エピソードを生成する関数 `episode(rng)` (状態列と報酬列を返す)を書き、first-visit MC:

```
V = np.zeros(7); returns_count = np.zeros(7)
for ep in range(N_EPISODES):
    states, rewards = episode(rng)
    G = 0.0; visited = set()
    for t in reversed(range(len(states))):
        G = rewards[t] + G # gamma = 1
        s = states[t]
        # TODO: first-visit判定(そのエピソード内で s の最初の訪問のときだけ)
        # 逐次平均 V[s] += (G - V[s]) / returns_count[s] で更新
```

を実装せよ(逆順に回して first-visit を扱うときは「その時刻より前に同じ状態が現れないか」で判定する。素直に前から2パスで処理してもよい)。

ステップ3 収束の測定

エピソード数 $N \in \{10, 10^2, 10^3, 10^4\}$ について、推定値と真値のRMS誤差

$\sqrt{\frac{1}{5} \sum_k (\hat{V}(k) - k/6)^2}$ を(乱数シードを変えて20回平均して)計算し、**両対数プロット**せよ。

✓ 確認ポイント

- $N = 10^4$ で $\hat{V} \approx (0.167, 0.333, 0.500, 0.667, 0.833)$ に近づく(各成分の誤差が数%以内)。
- 両対数プロットの傾きが約 $-1/2$ 、すなわち誤差 $\propto 1/\sqrt{N}$ 。大数の法則・中心極限定理とおりのモンテカルロの収束速度である。

課題4 TD(0) vs MC: バイアス・分散トレードオフを可視化する

対応理論: [強化学習の数理 1 基礎編 > 第8章 時間差分 \(TD\) 学習 — SARSAとQ学習](#) 8.1–8.2 節。

目的: 同じ課題3のランダムウォークで、TD(0) が (i) エピソード途中でも逐次更新できること、(ii) 序盤の学習がMCより速いこと(低分散の恩恵)を実測する。

ステップ1 TD(0) の実装

初期値 $\hat{V}(s) = 0.5$ (全状態)から、遷移 (S_t, R_{t+1}, S_{t+1}) ごとに

$$\hat{V}(S_t) \leftarrow \hat{V}(S_t) + \alpha [R_{t+1} + \hat{V}(S_{t+1}) - \hat{V}(S_t)]$$

を実装せよ(終端では $\hat{V}(S_{t+1}) = 0$ とする)。 $\alpha = 0.1$ 。

ステップ2 学習曲線の比較

MC(定数 $\alpha = 0.02$ の(7.1)型更新に変更したもの)とTD(0)($\alpha = 0.1$)について、エピソード数 0~200 にわたるRMS誤差(対真値 $k/6$)の推移を、シード100本の平均としてプロットせよ。

ステップ3 ステップサイズの影響

TD(0) の $\alpha \in \{0.05, 0.1, 0.2\}$ で同じ曲線を重ね描きし、「大きい α は序盤速いが到達精度が悪い(揺らぎが残る)」ことを確認せよ。Robbins-Monro条件($\sum \alpha_k = \infty, \sum \alpha_k^2 < \infty$; 定数 α はこれを満たさない)との関係を考察の代わりに [!note] としてノートに書き留めよ: 定数 α では誤差はゼロにならず、 α に比例した揺らぎの床に達して止まる。

✓ 確認ポイント

- 両曲線とも単調に誤差が減り、**最初の数十エピソードではTDがMCより明確に速い**(この課題設定はTD有利の古典例である)。
- α を大きくすると立ち上がりが速くなる代わりに、終盤の誤差の床が高くなる。
- TDはエピソード終了を待たずに毎ステップ更新している(コードの構造がそれを示している)ことを確認せよ——継続的タスクにも使える形である。

課題5 SARSA vs Q学習:崖歩き(Cliff Walking)

対応理論: [強化学習の数理 1 基礎編 > 第8章 時間差分\(TD\)学習 — SARSAとQ学習](#) 8.4–8.5 節。手計算では [強化学習の数理 3 演習 手計算編](#) 問題9.5。

目的: 方策オン(SARSA)と方策オフ(Q学習)の違いが、**学習される経路の質的な違い**として現れる有名な現象を再現する。

ステップ1 環境: 4×12の崖グリッド

- 4行×12列。左下がスタートS、右下がゴールG。SとGの間の最下行(10マス)が崖。
- 報酬: 通常の遷移 −1、崖に落ちると −100 でスタートへ戻る。ゴールで終了。 $\gamma = 1$ 。

ステップ2 ϵ -貪欲方策と2つの学習則

$\epsilon = 0.1$ (固定)、 $\alpha = 0.5$ で、

- SARSA: $Q(S_t, A_t) += \alpha[R + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)]$ (A_{t+1} は実際に選んだ次の行動)
- Q学習: $Q(S_t, A_t) += \alpha[R + \gamma \max_{a'} Q(S_{t+1}, a') - Q(S_t, A_t)]$

をそれぞれ500エピソード学習させよ。

ステップ3 比較

(a) エピソードごとの収益(報酬和)の移動平均を両方で重ね描き。(b) 学習後の貪欲方策で1エピソード走らせ、通る経路をグリッド上に印字せよ。

✓ 確認ポイント

- 学習後の貪欲経路: Q学習は崖すれすれの最短路、SARSAは崖から1~2行離れた安全路を通る。
- 学習中の平均収益(ϵ -探索込み)はSARSAの方が高い(Q学習は最適経路を学ぶが、探索で崖に落ちる事故を織り込まない)。
- 理由を自分の言葉で1段落書け: SARSAは「探索込みの自分自身(ϵ -貪欲方策)の Q^π 」を、Q学習は「探索とは無関係の Q^* 」を推定している——目標値の A_{t+1} と $\max_{a'}$ の一字の違いがこの差を生む(手計算編 問9.5 の数値例の大規模版)。

課題6 過大評価バイアスとDouble Q学習

対応理論: [強化学習の数理 1 基礎編 > 第8章 時間差分 \(TD\) 学習 — SARSAとQ学習](#) 8.5節の警告、[強化学習の数理 2 深層学習編 > 第3章 DQNの系譜 — Rainbowに至る改良の解剖](#) 3.1節。手計算では [強化学習の数理 3 演習 手計算編](#) 問題9.6・12。Double DQN・TD3の min 悲観化の本質はこの表形式実験に含まれている(縮小版)。

目的: max 演算がノイズを系統的に拾う現象を、最小のMDPで再現し、Double推定で消えることを確認する。

ステップ1 環境: バイアス検出用の2状態MDP

- 状態A(開始)。行動は「右」(報酬0で即終端)と「左」(報酬0で状態Bへ)。
- 状態B。行動は10本あり、どれを選んでも終端。報酬は $\mathcal{N}(-0.1, 1.0)$ からのサンプル。
- つまり左へ行く真の価値は $-0.1 < 0$ で、常に「右」が最適。しかしBの10行動のQ推定ノイズを max が拾うと、左が良く見えてしまう。

ステップ2 Q学習とDouble Q学習

$\epsilon = 0.1$ 、 $\alpha = 0.1$ 、 $\gamma = 1$ 。Double Q学習は2つの表 Q_1, Q_2 を持ち、毎回コイントスでどちらを更新するか選び、

$$Q_1(S, A) += \alpha[R + \gamma Q_2(S', \arg \max_{a'} Q_1(S', a')) - Q_1(S, A)]$$

(選択は Q_1 、評価は Q_2 。 Q_2 更新時は役割を入れ替え)。行動選択は $Q_1 + Q_2$ に対する ε -貪欲。

ステップ3 計測

300エピソード × 1000シードで、「状態Aで左を選んだ割合」のエピソード推移を両手法で重ね描きせよ。参考線として、最適下の水準 $\varepsilon/2 = 5\%$ (探索による左選択の下限)を引くこと。

✓ 確認ポイント

- Q学習は序盤、左選択率が大きく跳ね上がる(ピークで数十%)。真の価値が負なのに、10本の行動のノイズの max が正に見えるため。学習が進むと徐々に 5% 付近へ降りてくるが遅い。
- Double Q学習はほぼ最初から 5% 付近に張り付く。
- Bの行動数を10→2に減らす/報酬の分散を1→0.1に減らすと、Q学習のバイアスの山が小さくなることを確認せよ(バイアス $\sim \sigma\sqrt{2\ln|\mathcal{A}|}$ の定性的検証。[強化学習の数理 2 深層学習編 3.1節](#))。

課題7 線形関数近似:semi-gradient TD と状態集約

対応理論: [強化学習の数理 1 基礎編 > 第9章 関数近似への入り口 — 表形式の限界を超える](#)。手計算では [強化学習の数理 3 演習 手計算編](#) 問題11.3。

目的: 表を捨てて $\hat{v} = \mathbf{w}^\top \phi(s)$ に移行しても同じ更新則が動くこと、そして表現力の限界内の解に収束すること(誤差がゼロにならない)を見る。

ステップ1 環境と特徴量

課題3のランダムウォークを19状態版に拡張する(状態 1..19、両端の外が終端、右端で +1・左端で -1、開始は中央10。真値は $V(k) = (k - 10)/10$)。特徴量は状態集約:19状態を「1-5 / 6-10 / 11-15 / 16-19」の4グループに分け、 $\phi(s) \in \mathbb{R}^4$ を所属グループのone-hotとする。

ステップ2 semi-gradient TD(0)

$$\mathbf{w} \leftarrow \mathbf{w} + \alpha \delta_t \phi(S_t), \quad \delta_t = R_{t+1} + \gamma \mathbf{w}^\top \phi(S_{t+1}) - \mathbf{w}^\top \phi(S_t)$$

を実装し($\gamma = 1$ 、 $\alpha = 0.05$ 、10000エピソード、 α は後半 0.005 に落とす)、学習後の $\hat{v}(s)$ を真値と重ね描きせよ。

ステップ3 観察

(a) $\hat{v}$ が階段状(グループ内で一定)になること、(b) 各段がそのグループ内の真値の(訪問頻度重みつき)平均付近に来ること、(c) 特徴量を19次元one-hot(=表形式)に差し替えると誤差が消えること、を確認せよ。

✓ 確認ポイント

- 階段の4段はおよそ $(-0.7, -0.25, +0.25, +0.7)$ 前後(グループ割りが非対称なので端の段はやや偏る)。
- one-hot版はほぼ真値の直線 $(k - 10)/10$ を再現する。表形式が線形近似の特殊ケース($\phi = e_s$)であることのコードによる証明。
- 誤差がゼロにならないのはバグではない: 近似族の表現力の限界内での最良近似(の $\frac{1}{1-\gamma}$ 倍以内)に収束している(9.3節の結果)。

課題8 Deadly Triad: Bairdの反例で発散を起こす

対応理論: [強化学習の数理 1 基礎編 > 第9章 関数近似への入り口](#) — 表形式の限界を超える 9.4節。DQNの不安定性([強化学習の数理 2 深層学習編 第2章](#))の根っこを、線形・7状態というローカルで完全再現できる最小例で見る課題である。

目的: 「関数近似+ブートストラップ+方策オフ」が同時に揃うと、線形近似ですら価値推定が発散することを自分のマシンで起こす。

ステップ1 Bairdの星型MDP

- 状態 0..6。目標方策: 常に行動 solid をとる。solid は必ず状態6へ遷移する。報酬は常に0。
- したがって真値は自明に $V^\pi \equiv 0$ 。
- 挙動方策: 一様に全状態を訪れる(簡単のため、毎ステップ状態を一様ランダムに選んで1遷移だけ観測する形でよい)。ここに方策オフ性(挙動分布 $\neq$ 目標方策の訪問分布)がある。
- 特徴量($d = 8$ 、過剰パラメータ化):

```
Phi = np.zeros((7, 8))
for s in range(6):
    Phi[s, s] = 2.0; Phi[s, 7] = 1.0
Phi[6, 6] = 1.0; Phi[6, 7] = 2.0
w = np.ones(8); w[6] = 10.0          # 慣例的な初期値
gamma = 0.99
```

ステップ2 方策オフ semi-gradient TD(0)

毎ステップ: 状態 s を一様を選び、目標方策に従う遷移($s' = 6$, $r = 0$)について

$$\delta = 0 + \gamma \phi(6)^\top \mathbf{w} - \phi(s)^\top \mathbf{w}, \quad \mathbf{w} += \alpha \rho \delta \phi(s)$$

を実行($\alpha = 0.01$ 。 ρ は重点サンプリング比;この簡略設定では一様な状態選択を使うので $\rho = 1$ とした素朴版でもよいし、元の設定に忠実に $\rho = 7$ を掛けてもよい——どちらでも発散する)。 $\|\mathbf{w}\|$ を1000ステップ記録せよ。

ステップ3 発散の確認と「治療」

(a) $\|\mathbf{w}\|$ の推移を片対数プロットし、指数的発散を確認する。(b) 次のどれか1つを外すと発散が止まることを実験で確かめよ:

- ブートストラップをやめる(目標を真の収益 0、すなわちMC目標にする)
- 方策オフをやめる(状態を目標方策の訪問分布=ほぼ状態6のみ、からサンプルする)
- 関数近似をやめる($\phi = \mathbf{e}_s$ の7次元one-hotにする)

✓ 確認ポイント

- 素朴な方策オフ semi-gradient TD では $\|\mathbf{w}\|$ が**指数的に爆発**する(数百ステップで 10^3 、1000ステップで 10^8 規模。真値はゼロなのに!)
- 3要素のどれを外しても発散が止まる——**deadly triad は「3つ同時」のときだけ発火**することの実験的確認。
- この現象こそ、DQNが経験再生(分布の制御)とターゲットネットワーク(ブートストラップの自己言及の切断)を必要とした理由である。次の課題11でその処方箋を入れる。

課題9 REINFORCE とベースラインによる分散低減

対応理論: [強化学習の数理 1 基礎編 > 第10章 方策勾配法 — 方策を直接最適化する](#)。手計算では [強化学習の数理 3 演習 手計算編](#) 問題10。

目的: 方策を直接パラメータ化して勾配上昇で学習できること、そしてベースラインが**期待値を変えずに分散だけを下げる**ことを数値で確認する。

ステップ1 環境:短い回廊

- 4状態の数列 0, 1, 2, 3(3が終端ゴール、報酬 +1;それ以外の遷移は報酬 0)。開始は0。行動は左/右(端では留まる)。 $\gamma = 0.9$ 。
- **ひねり**:状態1だけ左右の効果が**反転**する(右を選ぶと左へ動く)。こうすると「常に右」は最適でなく、**確率の方策に意味が生まれる**……のだが、状態を区別できる表形式 softmaxなら各状態で決定論に収束できる。まずは素直に解かせる。

ステップ2 表形式softmax方策とREINFORCE

方策は各状態独立のsoftmax: $\pi_{\theta}(a|s) \propto e^{\theta_{s,a}}$ ($\theta \in \mathbb{R}^{4 \times 2}$)。スコア関数は手計算編 問10.4 の one-hot版:

$$\nabla_{\theta_{s,\cdot}} \ln \pi(a|s) = \mathbf{e}_a - \pi(\cdot|s)$$

エピソードを生成し、各時刻について $\theta_{S_{t,\cdot}} += \alpha \gamma^t G_t (\mathbf{e}_{A_t} - \pi(\cdot|S_t))$ を実装せよ ($\alpha = 0.1$ 、2000エピソード)。

ステップ3 ベースラインの追加と分散の測定

- (a) 状態価値の推定 $b(s) = \hat{V}(s)$ を、MC更新 $\hat{V}(S_t) += \alpha_v (G_t - \hat{V}(S_t))$ で並走させ、重みを $G_t - b(S_t)$ に置き換えた版を作る。
- (b) **勾配推定の分散を直接測る**: 学習を途中(たとえば200エピソード時点)で凍結し、その方策のまま500エピソード分の「1エピソードあたりの勾配推定量」を集め、成分ごとの分散の総和をベースラインあり/なしで比較せよ。
- (c) 学習曲線(エピソード収益の移動平均)を、あり/なし $\times$ シード20本平均で重ね描きせよ。

✓ 確認ポイント

- どちらの版も最終的にゴール到達方策(平均収益がほぼ理論上限)へ収束する——ベースラインは**不偏性を壊さない**(手計算編 問10.3 の実験版)。
- 凍結時点の勾配分散は、ベースラインありが**明確に小さい**(設定次第で数分の一)。
- 学習曲線はベースラインありの方が滑らかで速い。

課題10 アクター・クリティック:TD誤差を共有する

対応理論: [強化学習の数理 1 基礎編 > 第10章 方策勾配法 — 方策を直接最適化する](#) 10.5節、[強化学習の数理 2 深層学習編 > 第4章 深層方策勾配 \(I\) — A2C/A3C と一般化アドバンテージ推定 \(GAE\)](#) 4.1節。A2Cの縮小版(並列環境なし・表形式)である。

目的: MC収益 G_t をTD目標に置き換えることで、エピソード終了を待たない**完全オンライン**の方策学習が動くことを確認する。

ステップ1 実装

課題9と同じ環境・同じsoftmax方策で、1ステップごとに:

```
delta = r + gamma * V[s_next] * (not done) - V[s]      # TD誤差
V[s]      += alpha_w * delta                             # クリティック
theta[s, :] += alpha_t * I * delta * (onehot(a) - pi)   # アクター
I *= gamma                                              #  $\gamma^t$  因子
```

を実行せよ ($\alpha_w = 0.1$, $\alpha_t = 0.1$)。

ステップ2 比較

課題9のREINFORCE(ベースラインあり)と学習曲線を重ね、(a) 序盤の立ち上がり、(b) 曲線の滑らかさ、を比較せよ。

✓ 確認ポイント

- アクター・クリティックも同じ最適方策に到達する。
- 更新がエピソード内で毎ステップ走っている(コード構造)。REINFORCEはエピソード末尾まで更新できない。
- 同じ δ_t が2行(アクターとクリティック)で共有されている——「予想より良ければその行動を強化」という10.5節の記述がコード2行に対応することを確認せよ。

課題11 ミニDQN:リプレイバッファとターゲットネットの効果測定

対応理論: [強化学習の数理 2 深層学習編 > 第2章 DQN — 深層Q学習と不安定性への最初の処方箋](#)。Atari規模のDQNのローカル再現は対象外とし、その2大発明(経験再生・ターゲットネットワーク)の効果を、線形関数近似+崖歩き環境で切り分けて測る縮小版とする。手計算では [強化学習の数理 3 演習 手計算編](#) 問題11。

目的: 「素朴な近似Q学習」に経験再生とターゲットネットを1つずつ足し、学習の安定性がどう変わるかをアブレーション(部品の抜き差し)で観察する。

ステップ1 関数近似つきQ学習の骨格

課題5の崖歩き環境を使う。 $Q(s, a) = \mathbf{w}_a^\top \phi(s)$ 、特徴 $\phi(s)$ は**タイルコーディング風の粗い集約**: 状態の(行, 列)をそれぞれ2マス幅で区切ったone-hotの連結($2 + 6 = 8$ 次元)+バイアス項。この「近すぎる状態が同じ特徴を共有する」設計は、汎化と干渉を意図的に持ち込むためのものである。

ステップ2 4条件の比較実験

次の4条件を、同一シード集合(20本)で各500エピソード学習させ、エピソード収益の移動平均を4本重ね描きせよ。

1. **素朴版**: 遷移を観測するたび、その1遷移で semi-gradient Q学習更新。
2. **+リプレイ**: 遷移をバッファ(容量5000)に貯め、毎ステップ、バッファから32件を一様サンプルしてミニバッチ更新。
3. **+ターゲット**: 目標値の計算に凍結パラメータ $\mathbf{w}^-$ を使い、200更新ごとに $\mathbf{w}^- \leftarrow \mathbf{w}$ 。
4. **+両方**(=ミニDQN)。

```
# 目標値(条件3・4)
y = r + gamma * (not done) * np.max(phi_next @ W_target.T)
# 更新はつねにオンライン側 W に対して:
W[a] += alpha * (y - phi @ W[a]) * phi
```

ステップ3 観察

(a) 学習曲線の平均と、(b) シード間の**ばらつき**(帯として描く)を比較せよ。(c) 素朴版で崩壊(収益が一度上がってから激しく落ちる)が起きるシードの割合を数えよ。

✓ 確認ポイント

- 素朴版は動くこともあるが**シードによって不安定**(振動・崩壊が最も多い)。両方入り(条件4)が最も安定して高収益に到達する。
- リプレイだけ・ターゲットだけでも部分的に改善する——2つの発明が**別々の病理**(データ相関 / 動く目標)への処方箋であることの切り分け実験。
- 効果の出方は環境・特徴量・ハイパーパラメータに依存する(理論保証がない領域に入っている!)。「どの条件がどれくらい安定か」を自分の数字で語れるようにしておくこと。

課題12 GAE: λ で分散とバイアスのダイヤルを回す

対応理論: [強化学習の数理 2 深層学習編 > 第4章 深層方策勾配 \(I\) — A2C/A3C と一般化アドバンテージ推定 \(GAE\) 4.3節](#)。手計算では [強化学習の数理 3 演習 手計算編](#) 問題14。

目的: GAEの後ろ向き再帰を実装し、 λ がアドバンテージ推定量の分散(とバイアス)を連続的に動かすことを実測する。

ステップ1 実装と単体テスト

```
def gae(deltas, gamma, lam):
    A = np.zeros(len(deltas)); acc = 0.0
    for t in reversed(range(len(deltas))):
        acc = deltas[t] + gamma * lam * acc
        A[t] = acc
    return A
```

単体テスト: `deltas = [1, -0.5, 2]`, `gamma=0.9`, `lam=0.5` で `A = [1.18, 0.4, 2.0]` になること(手計算編 問14.4 の答えと一致)を `assert` せよ。

ステップ2 分散の実測

課題3の19状態ランダムウォーク(課題7版)で、方策は一樣ランダムに固定。クリティックは **わざと不正確**にする: 真値 $V(k) = (k - 10)/10$ に一樣ノイズ ± 0.3 を加えて固定した $\hat{V}$ を使う。

1000エピソードを生成し、開始状態のアドバンテージ推定 $\hat{A}_0^{\text{GAE}(\lambda)}$ を $\lambda \in \{0, 0.5, 0.9, 1.0\}$ で計算して、その**標本平均と標本分散**を表にせよ。

ステップ3 読み取り

- 分散が λ とともに単調増加すること ($\lambda = 0$ は δ_0 のみ=1遷移分のノイズ、 $\lambda = 1$ は $G_0 - \hat{V}(s_0)$ =全ステップのノイズ)。
- 平均(真のアドバンテージは0のはず。方策で条件づけない開始時点の平均アドバンテージは0)からのずれ=バイアスが、 λ が小さいほど($\hat{V}$ のノイズを通じて)大きく残ること。

✓ 確認ポイント

- 単体テストが通ること ([1.18, 0.4, 2.0])。
- 分散: $\lambda = 0$ が最小、 $\lambda = 1$ が最大で、間が単調につながる。
- 平均のずれ: $\lambda = 1$ ではほぼ0(不偏: $\hat{V}$ は $\hat{A}$ の式で $-\hat{V}(s_0)$ としてしか効かず、開始状態固定なら定数シフト)、 λ が小さいほどクリティックの誤差が混入する。「**実データをどこまで信じ、どこからブートストラップに切り替えるか**」のダイヤルが数字として見える。

課題13 ミニPPO:クリップは「行きすぎ」だけを止める

対応理論: [強化学習の数理 2 深層学習編 > 第5章 深層方策勾配 \(II\) — 性能差分補題・自然勾配・TRPO・PPO](#) 5.6節。TRPO(共役勾配・直線探索)はローカル演習の対象外とし、その思想の1次法への蒸留であるPPOのクリップ機構だけを、表形式softmax方策で抽出して確かめる。手計算では [強化学習の数理 3 演習 手計算編](#) 問題15・16。

目的: 「同じバッチで何エポックも更新を回す」というPPOの使い方が、クリップなしでは壊れ、クリップありでは安全になることを最小構成で見る。

ステップ1 クリップ目的関数の実装と単体テスト

```
def clipped_obj(rho, A, eps=0.2):  
    return np.minimum(rho * A, np.clip(rho, 1 - eps, 1 + eps) * A)
```

単体テスト(手計算編 問16 の4ケース): $(\text{rho}, A) = (1.5, 1) \rightarrow 1.2$ 、 $(0.7, 1) \rightarrow 0.7$ 、 $(0.7, -1) \rightarrow -0.8$ 、 $(1.5, -1) \rightarrow -1.5$ を assert せよ。

ステップ2 バッチ再利用の実験

課題9の回廊環境・表形式softmax方策で、次の学習ループを組む:

1. 現在の方策 π_{old} でエピソードを32本収集(状態・行動・ $\hat{A}_t$ 。 $\hat{A}$ は課題12のGAE、 $\lambda = 0.95$ 、クリティックはMC更新で並走)。
2. 同じバッチで K エポック、目的

$$L(\theta) = \frac{1}{N} \sum_t \text{clipped_obj}(\rho_t(\theta), \hat{A}_t), \quad \rho_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\text{old}}(a_t|s_t)}$$

の勾配上昇(ρ_t の θ 微分は $\rho_t \nabla \ln \pi_\theta$; クリップ発動時は勾配0にするのを忘れずに)。

3. $\pi_{\text{old}} \leftarrow \pi_\theta$ として1へ。

ステップ3 比較

$K = 10$ に固定し、(a) クリップあり、(b) クリップなし(素の $\rho_t \hat{A}_t$)、の学習曲線と、各更新後の平均確率比 $\bar{\rho}$ の推移を重ね描きせよ。

✓ 確認ポイント

- 単体テストが通ること。
- **クリップなし + 多エポック**では、 $\bar{\rho}$ が1から大きく離れ(2~数倍)、学習が振動・崩壊しやすい(古いデータで推定した勾配が新しい方策ではもはや勾配でない——5.1節の病理)。
- **クリップあり**では $\bar{\rho}$ が概ね $[1 - \epsilon, 1 + \epsilon]$ 近傍に留まり、同じ $K = 10$ でも学習が安定する。
- ϵ を 0.05 / 0.2 / 0.5 と振ると、「保守的で遅い $\leftrightarrow$ 大胆で不安定」のトレードオフが動くことを確認せよ。

課題14 ソフト価値反復:log-sum-exp と零温度極限

対応理論: [強化学習の数理 2 深層学習編 > 第7章 最大エントロピー強化学習 — ソフト Bellman方程式とSAC](#)。SAC本体(連続行動・再パラメータ化・DNN)は対象外とし、その理論的核であるソフトBellman方程式を表形式で解く縮小版とする。手計算では [強化学習の数理 3 演習 手計算編](#) 問題19。

目的: Bellman最適作用素の $\max$ を log-sum-exp に置き換えても反復が収束すること(縮小性の存続)、温度 $\alpha \rightarrow 0$ で通常の価値反復に連続的に接続することを確認する。

ステップ1 数値的に安定な log-sum-exp

素朴に `alpha * np.log(np.sum(np.exp(Q / alpha)))` と書くと、 α が小さいとき $e^{Q/\alpha}$ がオーバーフローする。最大値をくくり出す標準手法

$$\text{lse}_\alpha(Q) = \max_a Q_a + \alpha \ln \sum_a e^{(Q_a - \max_b Q_b)/\alpha}$$

を実装し、 $Q = [2, 0]$, $\alpha = 0.001$ で落ちずに ≈ 2.0 を返すことを確認せよ(この式変形自体、「lse は max + 補正項」という構造の証明にもなっている)。

ステップ2 ソフト価値反復

課題1の2状態MDP($\gamma = 0.9$)で、

$$Q_{k+1}(s, a) = R(s, a) + \gamma V_k(s'), \quad V_k(s) = \text{lse}_\alpha(Q_k(s, \cdot))$$

を収束まで反復し、収束後の V_{soft} と Boltzmann 方策 $\pi^*(a|s) = e^{(Q(s,a)-V(s))/\alpha}$ を出力せよ。
 $\alpha \in \{1.0, 0.5, 0.1, 0.01\}$ で実行する。

ステップ3 観察

(a) V_{soft} と $\pi^*(s_1)$ の α 依存性を表にする。(b) 各 α で誤差の片対数プロットを描き、収束レートが依然として $\gamma = 0.9$ であること(縮小性の存続)を確認する。(c) 方策のエントロピー $\mathcal{H}(\pi^*(\cdot|s_1))$ を α に対してプロットし、「温度を下げると凝縮する」ことを見る。

✓ 確認ポイント

- 収束値(小数3桁):

α	$V_{\text{soft}}(s_1)$	$V_{\text{soft}}(s_2)$	$\pi^*(\text{move} s_1)$
1.0	18.843	20.344	0.587
0.5	18.113	20.003	0.803
0.1	18.000	20.000	1.000
0.01	18.000	20.000	1.000

- $\alpha \rightarrow 0$ で $V_{\text{soft}} \rightarrow V^* = (18, 20)$ (課題1の値)、方策は貪欲(s_1 で move)へ凝縮する。
 $V_{\text{soft}} \geq V^*$ (エントロピーボーナス分だけ高い)であることにも注意。
- どの α でも誤差比は ≈ 0.9 : 「max $\rightarrow$ lse」の置換で収束理論が丸ごと生き残る(手計算編 問19.4)ことの数値的裏づけ。
- ステップ1の安定化を入れないと $\alpha = 0.01$ でオーバーフローすることを、あえて素朴版でも走らせて確認しておくといよい。

対象外としたトピックと、その本質の所在

以下は標準的なローカル環境での忠実な再現が難しい(計算資源・実装量・外部依存の点で)ため課題化していない。ただし、その**理論的な本質**は本テキストの縮小版課題に含まれている。

対象外のトピック	本質を体験できる課題
Atari規模のDQN・Rainbow	課題11(経験再生・ターゲットネット)+ 課題6(Double)+ 課題8(不安定性の根源)
TRPO(自然勾配・共役勾配)	課題13(信頼領域思想のクリップへの蒸留)+ 手計算編 問17(Fisher行列)
DDPG / TD3 / SAC(連続行動・DNN)	課題6(min系悲観化の動機)+ 課題14(ソフトBellman方程式)+ 手計算編 問18(DPGの連鎖律)
MCTS / AlphaZero / MuZero	課題2(プランニング=DPの原型。MCTSは「改善作用素」としてのGPI部品: 強化学習の数理 2 深層学習編 8.3節)
RLHF / DPO	手計算編 問20(Bradley-Terryの勾配とKL正則化閉形式が理論の全部品)

㊦ 結び

ここまでの14課題で、読者の手元には「Bellman方程式を解く」ことの実装的な意味——厳密に(課題1-2)、サンプルで(3-6)、近似の上で(7-8)、方策を直接動かして(9-10)、そして安定化の処方箋とともに(11-14)——が、動くコードとして残ったはずである。解説テキストの主張どおり、どのコードも同じ数行(目標値の計算と「(目標-推定)×ステップサイズ」)の変奏だったことを、diffを眺めて確かめてほしい。導出の細部に戻りたくなったら [強化学習の数理 3 演習 手計算編](#) へ、理論の全体像は [強化学習の数理 1 基礎編](#) と [強化学習の数理 2 深層学習編](#) へ。